

Licenciatura en Tecnología Digital

Inteligencia Artificial y Neurociencia - Reinforcement Learning

Algoritmos de aprendizaje + Guía 1

Clase práctica 2

Plan para hoy!

- Implementar los 3 algoritmos de aprendizaje vistos en las teóricas, experimentar con sus parámetros y preguntarnos sobre sus resultados. (65 min)
- Resolver ejercicios de guía solicitados y/o avanzar con el TP, ya con una implementación posible vista de los algoritmos. (30 min)

Licenciatura en Tecnología Digital

Inteligencia Artificial y Neurociencia - Reinforcement Learning

Monte Carlo

-

Algoritmo

Inicializar:

$\pi \leftarrow$ política al azar

$Q(s, a) \in \mathbb{R}$ arbitrariamente, $\forall s, a$

$Retornos(s, a) \leftarrow$ lista vacía, $\forall s, a$

Repetir:

Generar un episodio según π : $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$.

Para cada paso del episodio, $t = 0, 1, \dots, T - 1$:

$$G \leftarrow \sum_{k=t+1}^T \gamma^{k-t-1} R_k$$

Agregar G a $Retornos(S_t, A_t)$

$Q(S_t, A_t) \leftarrow$ promedio($Retornos(S_t, A_t)$)

$A^* \leftarrow \arg \max_a Q(S_t, a)$

$$\pi(a | S_t) \leftarrow \begin{cases} 1 - \varepsilon + \varepsilon / |\mathcal{A}(S_t)| & \text{si } a = A^* \\ \varepsilon / |\mathcal{A}(S_t)| & \text{si } a \neq A^* \end{cases}$$

Devuelve una política estocástica $\pi(a | s) \approx \pi_*$.

Licenciatura en Tecnología Digital

Inteligencia Artificial y Neurociencia - Reinforcement Learning

SARSA

-

Algoritmo

Inicializar $Q(s, a)$ arbitrariamente $\forall s \in \mathcal{S}, a \in \mathcal{A}(s)$

Repetir:

 Inicializar S

$A \leftarrow$ acción desde S según política ε -greedy basada en Q

 Repetir:

 Ejecutar la acción A ; observar R, S'

$A' \leftarrow$ acción desde S' según política ε -greedy basada en Q

$Q(S, A) \leftarrow Q(S, A) + \alpha [R + \gamma Q(S', A') - Q(S, A)]$

$S \leftarrow S'$

$A \leftarrow A'$

 hasta que S sea terminal

La tasa de aprendizaje $\alpha \in (0, 1]$ es un parámetro permite controlar la relevancia de la información más reciente, lo cual es útil en ambientes no estacionarios.

Licenciatura en Tecnología Digital

Inteligencia Artificial y Neurociencia - Reinforcement Learning

Q Learning

-

Algoritmo

Inicializar $Q(s, a)$ arbitrariamente $\forall s \in \mathcal{S}, a \in \mathcal{A}(s)$

Repetir:

 Inicializar S

 Repetir:

$A \leftarrow$ acción desde S según política ε -greedy basada en Q

 Ejecutar la acción A ; observar R, S'

$Q(S, A) \leftarrow Q(S, A) + \alpha [R + \gamma \max_a Q(S', a) - Q(S, A)]$

$S \leftarrow S'$

 hasta que S sea terminal

La tasa de aprendizaje $\alpha \in (0, 1]$ es un parámetro permite controlar la relevancia de la información más reciente, lo cual es útil en ambientes no estacionarios.

Licenciatura en Tecnología Digital

Inteligencia Artificial y Neurociencia - Reinforcement Learning

Ejercicios Guía

-

Ejercicios

Ejercicio 7. Demostrar que si $\forall t, R_t = 1$, entonces $G_t = \frac{1}{(1-\gamma)}$.

Ejercicio 8. Sea $p(s'|s, a)$ la probabilidad de llegar al estado s' al ejecutar la acción a en el estado s . Expresar $p(s'|s, a)$ en base a $p(s', r|s, a)$.

DEFINICIÓN: Probabilidad de llegar al estado s' con recompensa r , luego de ejecutar la acción a en el estado s :

$$p(s', r | s, a) \doteq \Pr\{S_t = s', R_t = r | S_{t-1} = s, A_{t-1} = a\}$$

La función $p : \mathcal{S} \times \mathcal{R} \times \mathcal{S} \times \mathcal{A} \rightarrow [0, 1]$ especifica la distribución de probabilidad de los efectos de cada par (s, a) :

$$\sum_{s' \in \mathcal{S}} \sum_{r \in \mathcal{R}} p(s', r | s, a) = 1 \quad \text{para cada } s \in \mathcal{S}, a \in \mathcal{A}(s)$$

La función p caracteriza por completo la dinámica del ambiente.

DEFINICIÓN: El objetivo del agente es maximizar el **retorno** (o ganancia acumulada esperada) a partir del tiempo t , que se define:

$$G_t \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots + \gamma^{T-t-1} R_T = \sum_{k=t+1}^T \gamma^{k-t-1} R_k$$

donde T es el último tiempo del **episodio**; γ es el **factor de descuento** aplicado a recompensas futuras ($0 \leq \gamma \leq 1$).

Ejemplos de episodios: partida de ajedrez; (intento de) escape de un laberinto; una vida en un juego de Atari. Cada episodio comienza de manera independiente del anterior, y concluye en un **estado terminal**.

Cuando la tarea prosigue y no tiene sentido hablar de episodios, decimos que la tarea es **continua** y $T = \infty$.

Es útil plantear a G_t en forma recursiva: $G_t = R_{t+1} + \gamma G_{t+1}$ ($t < T$).

Ejercicios

Ejercicio 15. Considerar el ejemplo visto en clase, que ilustra la aplicación del algoritmo Monte Carlo en un juego de BlackJack (sin ases). Suponer que inicialmente $Q(s, a) = 0, \forall s, a$, y que el agente ejecuta los mismos tres episodios dados en el ejemplo. Hacer un seguimiento manual de las sucesivas actualizaciones de Q , según el algoritmo SARSA y según Q-Learning, con $\gamma = 1$ y $\alpha = 0,5$.

Inicializar $Q(s, a)$ arbitrariamente $\forall s \in \mathcal{S}, a \in \mathcal{A}(s)$

Repetir:

 Inicializar S

$A \leftarrow$ acción desde S según política ε -greedy basada en Q

 Repetir:

 Ejecutar la acción A ; observar R, S'

$A' \leftarrow$ acción desde S' según política ε -greedy basada en Q

$Q(S, A) \leftarrow Q(S, A) + \alpha [R + \gamma Q(S', A') - Q(S, A)]$

$S \leftarrow S'$

$A \leftarrow A'$

 hasta que S sea terminal

La tasa de aprendizaje $\alpha \in (0, 1]$ es un parámetro que permite controlar la relevancia de la información más reciente, lo cual es útil en ambientes no estacionarios.