Inteligencia Artificial y Neurociencias

Licenciatura en Tecnología Digital, UTDT, 2S-2026

Profesores: Agustín Gravano, Andrés Rieznik
Auxiliares: Gerardo Del Toro, Antonella Giordano Furchi

Práctica: modelos de lenguaje, embeddings y atención

Consignas para resolver en clase

Ejercicio 1: un modelo de lenguaje con bigramas

Un modelo de bigramas estima la próxima palabra usando solamente la anterior:

$$P(w_i \mid w_1, \ldots, w_{i-1}) \approx P(w_i \mid w_{i-1}).$$

La probabilidad de una oración se obtiene multiplicando las transiciones, desde inicio hasta fin.

Anterior	**Siguiente**	P
$\langle inicio \rangle$	el	1,0
el	gato	0,6
el	pescado	0,4
gato	come	0,45
gato	$\langle fin \rangle$	0,55
pescado	come	0,1
pescado	$\langle fin \rangle$	0,9
come	pescado	0,8
come	gato	0,2

Bigramas: probabilidad de oraciones

EJERCICIO: Calcular, incluyendo $\langle inicio \rangle$ y $\langle fin \rangle$:

1. P(el gato come pescado).
2. P(el pescado come gato).

PREGUNTA: ¿Cuál de las dos oraciones es más probable?

Anterior	**Siguiente**	P
$\langle inicio \rangle$	el	1,0
el	gato	0,6
el	pescado	0,4
gato	come	0,45
gato	$\langle fin \rangle$	0,55
pescado	come	0,1
pescado	$\langle fin \rangle$	0,9
come	pescado	0,8
come	gato	0,2

Bigramas: generar una oración

EJERCICIO: Empezando en $\langle inicio \rangle$, generar una oración eligiendo siempre la palabra más probable en cada paso (*greedy*).

PREGUNTA: ¿Greedy genera la oración con mayor probabilidad total?

Si la respuesta es sí, justificarla. Si no, encontrar una oración más probable y comparar ambas probabilidades.

Anterior	**Siguiente**	P
$\langle inicio \rangle$	el	1,0
el	gato	0,6
el	pescado	0,4
gato	come	0,45
gato	$\langle fin \rangle$	0,55
pescado	come	0,1
pescado	$\langle fin \rangle$	0,9
come	pescado	0,8
come	gato	0,2

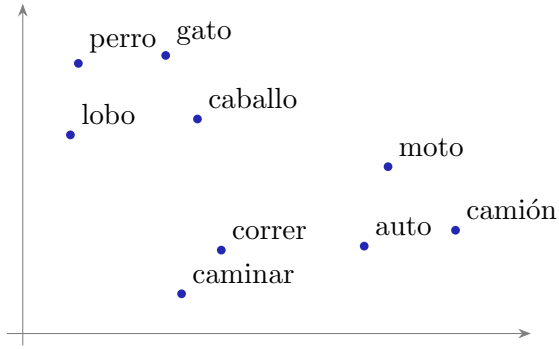
Bigramas: límites del modelo

Discusión: ¿Qué problemas aparecen cuando solo tenemos en cuenta la palabra anterior?

1. ¿Puede recordar información presentada muchas palabras antes?
2. ¿Qué ocurre con una combinación de palabras que nunca apareció en el corpus de entrenamiento?
3. ¿Qué ventajas y problemas tendría usar trigramas o 5-gramas?

Ejercicio 2: el espacio de embeddings

Las palabras pueden representarse mediante vectores.



$$\text{sim}(u, v) = \frac{u \cdot v}{\|u\| \, \|v\|}.$$

Embeddings: operaciones entre palabras

Además de comparar palabras por similitud, podemos realizar operaciones vectoriales sobre sus embeddings.

EJERCICIO: ¿A qué palabra esperarías aproximarte con la siguiente operación?

$$v(\text{Italia}) - v(\text{Roma}) + v(\text{París}) \approx v(\,?\,)$$

DISCUSIÓN: ¿Qué relación entre las palabras intentamos representar con esta operación?

Embeddings: sumas y restas (ejemplo de juguete)

Palabra	**Embedding**
rey	$(3, 1)$
reina	$(3, 3)$
hombre	$(1, 1)$
mujer	$(1, 3)$
príncipe	$(2, 1)$
princesa	$(2, 3)$
palacio	$(4, 2)$
corona	$(3, 2)$

EJERCICIO: Sin usar el vector de reina en la operación:

1. Proponer una combinación de sumas y restas para acercarse a reina (sin límite de palabras).
2. Calcular el vector resultante.
3. Compararlo con reina mediante similitud coseno.

PREGUNTA: ¿Estas analogías deben funcionar en cualquier modelo entrenado?

Embeddings reales: competencia por equipos

Usaremos un modelo preentrenado en español desde un notebook de Colab.
Reglas:

1. En cada ronda se anuncia una palabra objetivo.
2. Cada equipo propone una expresión con sumas y restas de tantos embeddings como quiera:

$$v(A) - v(B) + v(C) - v(D) + \cdots$$

3. No se permite incluir la palabra objetivo en la expresión.
4. En cada ronda gana la mayor similitud coseno con el objetivo.
5. Gana la competencia el equipo que gane más rondas.

Nota: Solo pueden usarse palabras con vector disponible en el modelo.

Competencia: primera ronda

Palabra objetivo:

INVIERNO

Ejercicio: Proponer una combinación libre de sumas y restas de embeddings que maximice la similitud coseno con la palabra objetivo, sin usarla directamente.

Competencia: segunda ronda

Palabra objetivo:

PUTIN

Ejercicio: Proponer una nueva combinación libre de sumas y restas de embeddings, sin incluir la palabra objetivo.

Competencia: tercera ronda

Palabra objetivo:

MESSI

Ejercicio: Proponer una combinación libre de sumas y restas de embeddings, sin incluir la palabra objetivo.

Embeddings estáticos y contexto

Una misma palabra puede tener significados diferentes según la oración:

Me senté en el banco de la plaza.

Fui al banco a pedir un préstamo.

Un embedding estático representa la palabra *banco* con un mismo vector en ambos casos. Una representación contextual incorpora información de otras palabras, como *plaza* o *préstamo*, para distinguir sus sentidos.

Atención: intuición

La atención permite combinar información de diferentes palabras para construir una representación dependiente del contexto. No todas las palabras de una oración aportan la misma información para una predicción dada. En un modelo de lenguaje, la representación contextual puede ayudar a asignar probabilidades diferentes a las posibles palabras siguientes.

Ejercicio 3: atención y predicción

Queremos que el modelo prediga la palabra que sigue a taller.

1. La grúa llevó el auto al taller _____.
2. La artista llevó el cuadro al taller _____.

Consigna:

1. ¿Qué palabra esperarían como continuación en cada caso?
2. Para predecir mejor, ¿a qué palabras anteriores convendría prestar más atención en cada oración?
3. ¿Por qué ayudaría cambiar la representación de *taller* según el contexto?

Cierre: tres formas de modelar lenguaje

Modelo	**Idea principal**
N-gramas	Estimar la próxima palabra a partir de un contexto limitado.
Embeddings	Representar palabras como vectores, donde podemos comparar similitudes.
Atención	Construir representaciones que incorporen información de otras palabras.