

Inteligencia Artificial y Neurociencias


Licenciatura en Tecnología Digital, UTDT, 2S-2026

Profesores: Agustín Gravano, Andrés Rieznik

Auxiliares: Gerardo Del Toro, Antonella Giordano Furchi

Aprendizaje por Refuerzo: Bandidos de k brazos

Máquina tragamonedas (*bandido*)



Al accionar la palanca, una máquina tragamonedas paga una **recompensa** numérica (ej.: \$0, \$2,5) según una función **estocástica** que podemos suponer **estacionaria** (que no varía en el tiempo).
Estocástica: su resultado no es fijo, involucra el azar.

Bandidos de k brazos



- **Acción:** elegir una palanca (o *brazo*) entre k posibles.
- Cada palanca otorga una recompensa numérica, según su propia distribución de probabilidad. La recompensa puede ser negativa.
- Todas las distribuciones desconocidas. Además, por ahora suponemos que son estacionarias (no varían en el tiempo).
- Cada acción es independiente de las anteriores.
- **Objetivo:** Maximizar las recompensas acumuladas sobre cierto período de tiempo.

¿Ideas?

[Ver notebook con agentes: 1) aleatorio, 2) que explora una vez, 3) que explora N veces.]

Bandidos de k brazos

Sea A_t la acción elegida en el tiempo t , con recompensa R_t .

El **valor** de una acción $a \in \mathcal{A}$ se define como:

$$q_*(a) \doteq \mathbb{E}[R_t \mid A_t = a]$$

Es como la esperanza de la recompensa de tomar esa acción

$Q_t(a)$ es una **estimación** de $q_*(a)$ en el instante de tiempo t .

En el instante t , llamamos acción **greedy** a una **acción a que tiene máximo valor estimado $Q_t(a)$** . (OBS.: Puede haber **más de una**.)

- **Explotación**: Elegir una acción **greedy**.
- **Exploración**: Elegir **otra acción**.

En el Aprendizaje por Refuerzo es importante buscar un **balance entre exploración y explotación**. Con la metáfora de los bandidos de k brazos podemos estudiarlo de manera simple.

A toda acción A_t le corresponde una recompensa R_t

Métodos action-value

Los **métodos action-value** estiman $Q_t(a)$ y usan esas estimaciones para **seleccionar las acciones a ejecutar**.

La forma más sencilla de computar la estimación $Q_t(a)$ es calcular el **promedio de recompensas** obtenidas al seguir la acción a :

$$\begin{aligned} Q_t(a) &\doteq \frac{\text{suma de recompensas al tomar } a \text{ antes de } t}{\text{cantidad de veces que se tomó } a \text{ antes de } t} \\ &= \frac{\sum_{i=1}^{t-1} R_i \cdot \mathbb{1}_{A_i=a}}{\sum_{i=1}^{t-1} \mathbb{1}_{A_i=a}} \end{aligned}$$

(o bien 0 si el denominador es 0)

OBS.: A medida que crece el denominador, $Q_t(a)$ converge a $q_*(a)$, gracias a la Ley de los Grandes Números.

Métodos action-value

Si ya computamos $Q_t(a)$ para todas las acciones disponibles, podemos usarla para seleccionar una acción greedy:

$$A_t \doteq \arg \max_a Q_t(a)$$

(con desempate aleatorio)


Otra forma de usar $Q_t(a)$ para elegir una acción:

- Con probabilidad ε (baja), se elige una acción al azar.
- Con probabilidad $1 - \varepsilon$, se elige una acción greedy.

A este método se lo conoce como ε -greedy.

Ejemplo: 10-armed bandits


Simulación de banditos de k brazos ($k = 10$). Los valores $q_*(a)$ de las acciones $a = 1, \dots, 10$ se muestran a continuación:



Ejemplo: 10-armed bandits

Una ejecución = Aplicación durante 1000 instantes de tiempo de un método de aprendizaje ϵ -greedy.

Evolución del porcentaje de elecciones óptimas, promediado sobre 2000 ejecuciones:



Implementación incremental

Después de tomar una acción particular por n -ésima vez, la estimación de su valor puede escribirse así:

$$\begin{aligned}Q_{n+1} &= \frac{1}{n} \sum_{i=1}^n R_i \\&= \frac{1}{n} \left(R_n + \sum_{i=1}^{n-1} R_i \right) \\&= \frac{1}{n} \left(R_n + (n-1) \frac{1}{n-1} \sum_{i=1}^{n-1} R_i \right) \\&= \frac{1}{n} \left(R_n + (n-1) Q_n \right) \\&= \frac{1}{n} \left(R_n + n Q_n - Q_n \right) \\&= Q_n + \frac{1}{n} \left[R_n - Q_n \right]\end{aligned}$$

(para $n = 1$: $Q_2 = R_1$ con Q_1 arbitrario)

Esto requiere almacenar sólo Q_n y n en memoria, y la actualización luego de tomar cada acción es $O(1)$. Es **mejor que almacenar todas las recompensas**.

Bandidos de k brazos: Algoritmo

Inicializar, para cada $a = 1 \dots k$:

$$Q(a) \leftarrow 0$$

$$N(a) \leftarrow 0 \text{ cuántas veces se tomó la acción } a \text{ hasta el momento}$$

Repetir:

$$A \leftarrow \begin{cases} \text{una acción al azar} & \text{con probabilidad } \varepsilon \\ \arg \max_a Q(a) & \text{con probabilidad } 1 - \varepsilon \text{ (greedy)} \end{cases}$$

$$R \leftarrow \text{bandido}(A)$$

$$N(A) \leftarrow N(A) + 1$$

$$Q(A) \leftarrow Q(A) + \frac{1}{N(A)} [R - Q(A)]$$

(Si hay empate en el caso greedy ($1 - \varepsilon$), se desempata al azar.)

Actualización de estimaciones

$$Q_{n+1} = Q_n + \frac{1}{n} [R_n - Q_n]$$

Esta forma de actualizar estimaciones es frecuente en el Aprendizaje por Refuerzo:

$$NuevaEst = ViejaEst + TasaApr [Objetivo - ViejaEst]$$

donde:

- *ViejaEst* y *NuevaEst* son las estimaciones vieja y nueva.
- *TasaApr* es una **tasa de aprendizaje**; suele denotarse α .
- $[Objetivo - ViejaEst]$ se denomina **error de estimación**.

Problemas no estacionarios

El método visto es efectivo para problemas **estacionarios**, en los cuales los **valores** de las acciones **no varían** en el tiempo.

Para problemas **no estacionarios** (el caso más realista), tiene sentido dar **mayor peso a recompensas recientes**.

En lugar de:

$$Q_{n+1} = Q_n + \frac{1}{n} [R_n - Q_n],$$

ahora usamos una tasa de aprendizaje $\alpha \in (0, 1]$ constante:

$$Q_{n+1} = Q_n + \alpha [R_n - Q_n]$$

Problemas no estacionarios


De esta manera, es fácil ver que Q_{n+1} es el promedio ponderado de recompensas pasadas y la estimación inicial Q_1 :

$$\begin{aligned}Q_{n+1} &\doteq Q_n + \alpha [R_n - Q_n] \\&= \alpha R_n + (1 - \alpha) Q_n \\&= \alpha R_n + (1 - \alpha) [\alpha R_{n-1} + (1 - \alpha) Q_{n-1}] \\&= \alpha R_n + (1 - \alpha) \alpha R_{n-1} + (1 - \alpha)^2 Q_{n-1} \\&= \alpha R_n + (1 - \alpha) \alpha R_{n-1} + (1 - \alpha)^2 \alpha R_{n-2} + \\&\quad \dots + (1 - \alpha)^{n-1} \alpha R_1 + (1 - \alpha)^n Q_1 \\&= (1 - \alpha)^n Q_1 + \sum_{i=1}^n \alpha (1 - \alpha)^{n-i} R_i\end{aligned}$$

OBS.: Como $1 - \alpha < 1$, entonces $(1 - \alpha)^{n-i}$ decrece exponencialmente cuando $i \rightarrow 0$.

Aprendizaje por Refuerzo: Bandidos de k brazos

- Guía de ejercicios.
- Próxima clase: tema nuevo. Procesos de Decisión de Markov.



$$S_t \in \mathcal{S}; A_t \in \mathcal{A}(S_t); R_t \in \mathcal{R} \subset \mathbb{R}$$