

Inteligencia Artificial y Neurociencias

Licenciatura en Tecnología Digital, UTDT, 2S-2026

Profesores: Agustín Gravano, Andrés Rieznik

Auxiliares: Gerardo Del Toro, Antonella Giordano Furchi

Métodos Monte Carlo

¿Cómo estimar una política óptima π_* ?

Los métodos **Monte Carlo** son una familia de métodos numéricos que permiten obtener soluciones a problemas matemáticos por medio de pruebas aleatorias repetidas.

Ejemplo: estimación de π

En **Aprendizaje por Refuerzo**, los métodos Monte Carlo se basan en generar episodios, observar y aprender de lo ocurrido.

Como no conocemos $p(s', r | s, a)$, nuestro agente aprenderá mediante interacciones reales con el ambiente.

Algoritmo MC para estimar π_* (primera versión)

Inicializar:

$\pi \leftarrow$ política al azar **No tiene criterio para elegir una acción**

$Q(s, a) \in \mathbb{R}$ arbitrariamente, $\forall s, a$

$Retornos(s, a) \leftarrow$ lista vacía, $\forall s, a$

Repetir:

Generar un episodio según π : $S_0, A_0, R_1, S_1, A_1, R_2, S_2, \dots, S_{T-1}, A_{T-1}, R_T$.

Para cada paso del episodio, $t = 0, 1, \dots, T - 1$:

$G_t \leftarrow \sum_{k=t+1}^T \gamma^{k-t-1} R_k$ **Calcular retornos para cada t**

Agregar G_t a $Retornos(S_t, A_t)$ **Actualizar lista de retornos**

$Q(S_t, A_t) \leftarrow$ promedio($Retornos(S_t, A_t)$) **promedia los retornos de c/ episodio**

$\pi(S_t) \leftarrow \arg \max_a Q(S_t, a)$ **se actualiza la política en St**

Devuelve una política determinística $\pi(s) \approx \pi_*$.

va tendiendo a *

Algoritmo MC para estimar π_* (primera versión)

Problema:

- $Q(s, a)$ converge a $q_*(s, a)$ a medida que la cantidad de visitas a (s, a) tiende a infinito.
- Pero muchos pares (s, a) serán visitados muy pocas veces (o nunca), y para ellos no podremos estimar $q_*(s, a)$. Esto es porque se elige la acción en modo greedy

Por eso, debemos intentar visitar todos los estados y acciones.

Recordemos de k -bandidos que una forma de **explorar** el espacio de estados y acciones es mediante una política ϵ -greedy:

- con prob. ϵ se elige una acción al azar;
- con prob. $1 - \epsilon$ se elige A^* : la acción greedy según la política actual.

Formalmente:

$$\pi(a|s) = \begin{cases} 1 - \epsilon + \frac{\epsilon}{|\mathcal{A}(s)|} & \text{si } a = A^* \\ \frac{\epsilon}{|\mathcal{A}(s)|} & \text{si } a \neq A^* \end{cases}$$

Algoritmo MC para estimar π_* (final)

Inicializar: **esto se mantiene igual**

$\pi \leftarrow$ política al azar

$Q(s, a) \in \mathbb{R}$ arbitrariamente, $\forall s, a$

$Retornos(s, a) \leftarrow$ lista vacía, $\forall s, a$

Repetir: **también**

Generar un episodio según π : $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$.

Para cada paso del episodio, $t = 0, 1, \dots, T - 1$:

$$G_t \leftarrow \sum_{k=t+1}^T \gamma^{k-t-1} R_k$$

Agregar G_t a $Retornos(S_t, A_t)$

$$Q(S_t, A_t) \leftarrow \text{promedio}(Retornos(S_t, A_t))$$

$$A^* \leftarrow \arg \max_a Q(S_t, a)$$

$$\pi(a | S_t) \leftarrow \begin{cases} 1 - \varepsilon + \varepsilon / |\mathcal{A}(S_t)| & \text{si } a = A^* \\ \varepsilon / |\mathcal{A}(S_t)| & \text{si } a \neq A^* \end{cases}$$

permite la exploración

Devuelve una política estocástica $\pi(a | s) \approx \pi_*$.