

Inteligencia Artificial y Neurociencias

Licenciatura en Tecnología Digital, UTDT, 2S-2026

Profesores: Agustín Gravano, Andrés Rieznik

Auxiliares: Gerardo Del Toro, Antonella Giordano Furchi

Aprendizaje por Refuerzo: Procesos de Decisión de Markov

Procesos de Decisión de Markov



En los banditos de k brazos, estimamos $q_*(a)$ (el valor de cada acción) para decidir cuál acción ejecutar. Cada elección es independiente de las anteriores.

Ahora incorporamos el concepto de estado $s \in \mathcal{S}$ y vamos a estimar:


- $q_*(s, a)$ (el valor de la acción a en el estado s)
- $v_*(s)$ (el valor del estado s)

Los Procesos de Decisión de Markov (MDP) son un formalismo útil para modelar el proceso de toma de decisiones secuenciales, en los que cada decisión afecta a las siguientes.

Procesos de Decisión de Markov

Un **proceso de decisión de Markov** (MDP) es una tupla $(\mathcal{S}, \mathcal{A}, \mathcal{R}, p)$, donde $\mathcal{S}$, $\mathcal{A}$ y $\mathcal{R}$ son los estados, acciones y recompensas (todos conjuntos finitos) y p define la dinámica del MDP.


El tiempo transcurre de manera **discreta**: $t = 0, 1, 2, 3, \dots$



$A_t \in \mathcal{A}(S_t)$ es la acción tomada en el tiempo t desde el estado $S_t \in \mathcal{S}$. Se obtiene la recompensa $R_{t+1} \in \mathcal{R}$ y se avanza al estado S_{t+1} .

Una **trayectoria** se define como una secuencia $S_0, A_0, R_1, S_1, A_1, R_2, S_2, A_2, R_3, \dots$. Por ejemplo, R_2 y S_2 son el **efecto** de haber ejecutado la acción A_1 en el estado S_1 .

Ejemplo: Grid world



$$\mathcal{S} = \{A, B, C, D, E, F\}$$

$$\mathcal{R} = \{0, -50, 100\}$$

$$\mathcal{A}(A) = \{\downarrow, \rightarrow\}$$

$$\mathcal{A}(D) = \{\uparrow, \rightarrow\}$$

$$\mathcal{A}(B) = \{\leftarrow, \downarrow, \rightarrow\}$$

$$\mathcal{A}(E) = \{\leftarrow, \uparrow, \rightarrow\}$$

$$\mathcal{A}(C) = \{\leftarrow, \downarrow\}$$

$$\mathcal{A}(F) = \emptyset \text{ (estado terminal)}$$

Las acciones posibles según cada estado.

En el estado A sólo se puede ir para abajo o a la derecha.

Procesos de Decisión de Markov

DEFINICIÓN: Probabilidad de llegar al estado s' con recompensa r , luego de ejecutar la acción a en el estado s :

$$p(s', r | s, a) \doteq \Pr\{S_t = s', R_t = r | S_{t-1} = s, A_{t-1} = a\}$$

~~Esta probabilidad será 1 si el ambiente es determinístico (siempre llegás a lo mismo). No siempre es determinístico estocástico.~~

La función $p : \mathcal{S} \times \mathcal{R} \times \mathcal{S} \times \mathcal{A} \rightarrow [0, 1]$ especifica la distribución de probabilidad de los efectos de cada par (s, a) :

$$\sum_{s' \in \mathcal{S}} \sum_{r \in \mathcal{R}} p(s', r | s, a) = 1 \quad \text{para cada } s \in \mathcal{S}, a \in \mathcal{A}(s)$$

La función p caracteriza por completo la dinámica del ambiente.

La probabilidad de cada posible valor de (S_t, R_t) depende sólo de (S_{t-1}, A_{t-1}) , y no de estados o acciones anteriores.

Esto se conoce como la **propiedad de Markov**. Restringe cómo definimos nuestros estados, que deberían incluir toda la información del pasado que será relevante para el futuro.

Ejemplo: Grid world resbaladizo (estocástico)

Supongamos que el suelo está resbaladizo. Al ejecutar cualquier acción, con cierta probabilidad, podemos terminar en un estado distinto del deseado y/o recibir una penalidad.

Formalmente, para el estado A y la acción $\rightarrow$ podríamos tener, por ejemplo:

$$p(B, 0 \mid A, \rightarrow) = 0,9$$

$$p(B, -1 \mid A, \rightarrow) = 0,04$$

$$p(D, 0 \mid A, \rightarrow) = 0,04$$

$$p(D, -1 \mid A, \rightarrow) = 0,02$$

Y para el estado C y la acción $\downarrow$, podría ser:


$$p(F, 100 \mid C, \downarrow) = 0,98$$

$$p(B, -1 \mid C, \downarrow) = 0,02$$

etc.

Ejemplo: Grid world determinístico

Es más sencillo usar ejemplos con ambientes **determinísticos**; son más intuitivos, fáciles de entender y de visualizar:



$$p(B, 0 | A, \rightarrow) = 1$$

$$p(s, r | A, \rightarrow) = 0 \quad \forall (s, r) \neq (B, 0)$$

$$p(F, 100 | C, \downarrow) = 1$$

$$p(s, r | C, \downarrow) = 0 \quad \forall (s, r) \neq (F, 100)$$

Por eso, vamos a usar casi siempre ejemplos determinísticos.

Pero no debemos perder de vista el caso general estocástico, con la caracterización completa del ambiente dada por $p(s', r | s, a)$.

Retornos y episodios

DEFINICIÓN: El objetivo del agente es maximizar el **retorno** (o ganancia acumulada esperada) a partir del tiempo t , que se define:

$$G_t \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots + \gamma^{T-t-1} R_T = \sum_{k=t+1}^T \gamma^{k-t-1} R_k$$

donde T es el último tiempo del **episodio**; γ es el **factor de descuento** aplicado a recompensas futuras ($0 \leq \gamma \leq 1$).

Ejemplos de episodios: partida de ajedrez; (intento de) escape de un laberinto; una vida en un juego de Atari. Cada episodio comienza de manera independiente del anterior, y concluye en un **estado terminal**.

Cuando la tarea prosigue y no tiene sentido hablar de episodios, decimos que la tarea es **continua** y $T = \infty$.

Es útil plantear a G_t en forma recursiva: $G_t = R_{t+1} + \gamma G_{t+1}$ ($t < T$).

Sobre el factor de descuento

El **factor de descuento** γ es un parámetro del agente.

Determina cuánto valora recompensas cercanas/lejanas en el tiempo.

$$G_t = R_{t+1} + \gamma G_{t+1} \quad (t < T)$$
$$(0 \leq \gamma \leq 1)$$

- Si $\gamma = 0$, el agente es **miope**: sólo valora la recompensa inmediata.
- Cuando $\gamma \rightarrow 0$, valora más las recompensas más cercanas.
- Cuando $\gamma \rightarrow 1$, valora más las recompensas más lejanas.

Analogía con la inflación: Acordamos hacer un trabajo. Nos van a pagar un monto fijo en pesos cuando lo hayamos terminado. La tasa de inflación afectará nuestro comportamiento: con una inflación alta, intentaremos terminar el trabajo lo más rápido posible, para no perder dinero.

Así, una tasa de inflación alta funciona como un factor de descuento bajo, que licúa las recompensas futuras.

Ejercicio: Tatetí

- ¿Cuáles son los estados del juego?
- ¿Qué acciones tiene disponibles el agente en cada turno?
- ¿Cuáles son las recompensas?
- ¿Cómo se define $p(s', r \mid s, a)$?
- ¿Es un ambiente determinístico o estocástico?

Políticas y funciones de valor

DEFINICIÓN: Una **política** $\pi(a|s)$ es la probabilidad de que el agente ejecute la acción $a \in \mathcal{A}(s)$ en el estado $s \in \mathcal{S}$.

En general, consideramos políticas **estocásticas**. Si π determina una única acción a en cada estado s , π es **determinística**.

DEFINICIÓN: **Valor del estado s , según π :**

$$v_{\pi}(s) \doteq \mathbb{E}_{\pi}[G_t \mid S_t = s]$$

Es el retorno esperado de seguir la política π a partir de $s \in \mathcal{S}$.

DEFINICIÓN: **Valor de la acción a en el estado s , según π :**


$$q_{\pi}(s, a) \doteq \mathbb{E}_{\pi}[G_t \mid S_t = s, A_t = a]$$

Es el retorno esperado de ejecutar a en s , para luego seguir π .


PROPIEDAD: $q_{\pi}(s, a) = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s, A_t = a]$

Supongamos que elegimos como factor de descuento $\gamma = 0,9$.


Ambiente:




Política π (determinística)



v_π : Valor de los estados según π



q_π : Valor de las acciones según π



Políticas óptimas

DEFINICIÓN: Dadas dos políticas π, π' , decimos que $\pi \geq \pi'$ sii $v_\pi(s) \geq v_{\pi'}(s) \quad \forall s \in \mathcal{S}$.

DEFINICIÓN: Una política π_* es **óptima** si $\pi_* \geq \pi'$ para toda política π' .

Luego, podemos definir las **funciones de valor óptimas**:


$$v_*(s) \doteq \max_{\pi} v_{\pi}(s) \quad \forall s \in \mathcal{S}$$

$$q_*(s, a) \doteq \max_{\pi} q_{\pi}(s, a) \quad \forall s \in \mathcal{S}, a \in \mathcal{A}(s)$$


$$q_*(s, a) = \mathbb{E}[R_{t+1} + \gamma v_*(S_{t+1}) \mid S_t = s, A_t = a]$$

Supongamos que elegimos como factor de descuento $\gamma = 0,9$.


Ambiente:




Política óptima π_*



v_* : Valor de los estados según π_*



q_* : Valor de las acciones según π_*



Búsqueda de políticas óptimas

Las funciones de valor óptimas v_* y q_* son desconocidas para el agente, quien intentará estimarlas.

El Aprendizaje por Refuerzo tiene distintos métodos para estimar v_* y q_* , de modo de usar esas estimaciones para definir buenas políticas.

Si conociéramos la función $p(s', r | s, a)$ (o sea, tenemos un modelo del ambiente), podríamos usar métodos *model-based*; ejemplo: el algoritmo de programación dinámica Value Iteration. Pero (casi) nunca conocemos p ; estos métodos solo tienen interés teórico.

Si no conocemos $p(s', r | s, a)$, deberemos usar métodos *model-free*; ejemplos: Monte Carlo y Q-Learning.