Inteligencia Artificial y Neurociencias

Licenciatura en Tecnología Digital, UTDT, 2S-2026

Profesores: Agustín Gravano, Andrés Rieznik
Auxiliares: Gerardo Del Toro, Antonella Giordano Furchi

Gramáticas libres de contexto

Gramáticas libres de contexto

Una gramática libre de contexto (GLC) es una tupla (V, T, P, S):

- V es un conjunto de variables (no terminales)
- T es un conjunto de terminales
- P es un conjunto de producciones (reglas) de la forma $A \to \alpha$, con $A \in V$, $\alpha \in (V \cup T)^*$
- $S \in V$ es una variable especial llamada símbolo inicial

Derivación: $\alpha \overset{*}{\underset{G}{\Rightarrow}} \beta$ ("α deriva β") si, comenzando en la cadena α, podemos aplicar 0 o más producciones de P para llegar a la cadena β.

Lenguaje generado por una GLC G: $L(G) = \left\{ w \mid w \in T^*, S \overset{*}{\underset{G}{\Rightarrow}} w \right\}$

Decimos que L es un lenguaje libre de contexto (LLC) si $L = L(G)$ para alguna GLC G.

Dos GLCs G_1, G_2 son equivalentes si $L(G_1) = L(G_2)$.

Gramáticas libres de contexto

Ejemplo: Sea una gramática $G = (V, T, P, S)$, donde $V = \{S\}$, $T = \{a, b\}$ y $P = \{S \to aSb,\ S \to ab\}$.

Si aplicamos la primera producción $n - 1$ veces (para $n \geq 1$), seguida de una única aplicación de la segunda producción, obtenemos:

$$S \Rightarrow aSb \Rightarrow aaSbb \Rightarrow a^3Sb^3 \Rightarrow ... \Rightarrow a^{n-1}Sb^{n-1} \Rightarrow a^nb^n$$

Como este es el único tipo de cadenas que podemos generar con G, concluimos que $L(G) = \{a^nb^n \mid n \geq 1\}$.

Ejercicio: ¿Qué lenguaje genera la siguiente gramática?

$$S \to aSa \mid T$$
$$T \to bTb \mid W$$
$$W \to cWc \mid c$$

Ejemplo:

Gramática:

$$\texttt{<expresión>} \rightarrow \texttt{<expresión> + <expresión>}$$
$$\texttt{<expresión>} \rightarrow \texttt{<expresión> * <expresión>}$$
$$\texttt{<expresión>} \rightarrow \texttt{(<expresión>)}$$
$$\texttt{<expresión>} \rightarrow \texttt{id}$$

Derivación:

$$\begin{aligned}
\texttt{<expresión>} &\Rightarrow \texttt{<expresión> * <expresión>} \\
&\Rightarrow \texttt{(<expresión>) * <expresión>} \\
&\Rightarrow \texttt{(<expresión>) * id} \\
&\Rightarrow \texttt{(<expresión> + <expresión>) * id} \\
&\Rightarrow \texttt{(<expresión> + id) * id} \\
&\Rightarrow \texttt{(id + id) * id}
\end{aligned}$$

Árboles de derivación

Llamamos árbol de derivación (o árbol de *parsing*) para una GLC $G = (V, T, P, S)$, a un árbol con estas características:

- La raíz es S (símbolo inicial).
- Los nodos internos tienen una etiqueta en V (variables).
- Las hojas tienen una etiqueta en $\{\epsilon\} \cup T$ (terminales).
- Si un nodo interno tiene:
  - etiqueta $A \in V$
  - k hijos con etiquetas $X_1, X_2, ..., X_k \in V \cup T \cup \{\varepsilon\}$

  entonces en P hay una producción $A \to X_1 X_2 ... X_k$
- Si un nodo tiene etiqueta ϵ, entonces es una hoja.

Pertenencia - Parsing

Dados una GLC $G = (V, T, P, S)$ y una cadena $x \in T^*$, podemos determinar si $x \in L(G)$ mediante un algoritmo de parsing.

Cuando $x \in L(G)$, el parser puede además devolver un árbol de derivación de x.

Existen varios algoritmos de parsing, con distintas características.

Ejemplo: Algoritmo CYK (Cocke-Younger-Kasami)

- Algoritmo de programación dinámica
- Requiere que la gramática esté en FNC [1]
- $O(N^3)$, donde N es la longitud de la cadena a parsear

Demo online: `http://lxmls.it.pt/2015/cky.html`

---

[1] Teorema: Cualquier GLC puede convertirse a la Forma Normal de Chomsky (FNC), tal que todas sus producciones sean de la forma $A \to BC$ o $A \to a$, donde $A, B, C \in V$, $a \in T$. (Demo: HMU, sec 7.1.5)

Jerarquía de Chomsky

Tipo 3: Lenguajes regulares

- Definibles mediante expresiones regulares y gramáticas regulares

Tipo 2: Lenguajes libres de contexto

- Definibles mediante gramáticas libres de contexto
- Ejemplo: $\{a^n b^n \mid n \geq 1\}$ no es un lenguaje regular, pero sí es libre de contexto.

Tipo 1: Lenguajes sensibles al contexto

- Definibles mediante gramáticas sensibles al contexto
- Ejemplo: $\{a^n b^n c^n \mid n \geq 1\}$ no es un lenguaje libre de contexto, pero sí es sensible al contexto.

Tipo 0: Lenguajes recursivamente enumerables

- Definibles mediante gramáticas sin restricciones
- Acá *recursivo* es sinónimo de *computable*: son los lenguajes cuyas cadenas pueden ser enumeradas de alguna manera, o bien aceptadas por una *máquina de Turing*.

Lenguajes naturales

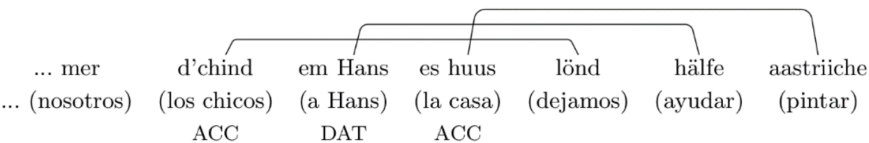
Los lenguajes naturales (como el español) claramente **no son regulares**. Es posible construir oraciones de la forma $a_1a_2a_3b_3b_2b_1$:

El sistema [que el equipo [que María lideró] implementó] falló.

El gato [que el perro [que Juan adoptó] persiguió] escapó.

y estas estructuras (parecidas a los palíndromos) escapan a los LR.

Han existido fuertes debates sobre si los lenguajes naturales son **libres de contexto**. En líneas generales, podemos decir que sí lo son, salvo en pocas excepciones, como por ejemplo:



"...nosotros dejamos a los chicos ayudar a Hans a pintar la casa", ejemplo (muy raro) en alemán suizo de interdependencias seriales de la forma $a_1a_2a_3b_1b_2b_3$, que escapa a los LLC.

La concordancia de género y número también causa problemas a las GLC: *Mi amiga me llamó ayer para contarme que estaba preocupada.*

GLC en español - Ejemplo de juguete

Gramática:

$$
\begin{aligned}
\textit{Oración} &\rightarrow \textit{FraseNominal}\ \ \textit{FraseVerbal} \\
\textit{FraseNominal} &\rightarrow \textit{Artículo Sustantivo} \mid \textit{Sustantivo Adjetivo} \\
\textit{Artículo} &\rightarrow \text{el} \mid \text{la} \\
\textit{Sustantivo} &\rightarrow \text{sapo} \mid \text{piel} \mid \text{pelo} \\
\textit{Adjetivo} &\rightarrow \text{verde} \mid \text{largo} \\
\textit{FraseVerbal} &\rightarrow \textit{Verbo FraseNominal} \mid \textit{Verbo Adverbio} \\
\textit{Verbo} &\rightarrow \text{tiene} \mid \text{salta} \\
\textit{Adverbio} &\rightarrow \text{alegremente}
\end{aligned}
$$

Derivación:

$$
\begin{aligned}
\textit{Oración} &\Rightarrow \textit{FraseNominal}\ \ \textit{FraseVerbal} \\
&\Rightarrow \textit{Artículo Sustantivo FraseVerbal} \\
&\Rightarrow \text{el } \textit{Sustantivo FraseVerbal} \\
&\Rightarrow \text{el sapo } \textit{FraseVerbal} \\
&\Rightarrow \text{el sapo } \textit{Verbo FraseNominal} \\
&\Rightarrow \text{el sapo tiene } \textit{FraseNominal} \\
&\Rightarrow \text{el sapo tiene } \textit{Sustantivo Adjetivo} \\
&\Rightarrow \text{el sapo tiene piel } \textit{Adjetivo} \\
&\Rightarrow \text{el sapo tiene piel verde}
\end{aligned}
$$

Gramáticas libres de contexto probabilísticas (GLCP)

Una GLC probabilística es una tupla (V, T, P, S).

Todas las producciones en P tienen la forma $A \to \alpha\ [p]$, donde $A \in V$, $\alpha \in (V \cup T)^*$, $p \in \mathbb{R}$, $0 \leq p \leq 1$.

p es la probabilidad de expandir la variable A con la producción dada. Es decir, $p = P(A \to \alpha \mid A)$, y se cumple que $\sum_\beta P(A \to \beta \mid A) = 1$ vale para toda $A \in V$.

Así, es natural hablar de la probabilidad de un parsing:

$P(T) = \prod_{i=1}^{n} P(A_i \to \beta_i)$, donde $A_i \to \beta_i$ son las n reglas aplicadas en la construcción del árbol de parsing T.

GLCP en español - Ejemplo de juguete

$$
\begin{aligned}
\textit{Oración} &\rightarrow \textit{FraseNominal}\ \textit{FraseVerbal} && [0.6] \\
\textit{Oración} &\rightarrow \textit{FraseVerbal} && [0.35] \\
\textit{Oración} &\rightarrow \textit{FraseNominal} && [0.05] \\
&\ldots \\
\textit{Sustantivo} &\rightarrow \text{sapo} && [0.4] \\
\textit{Sustantivo} &\rightarrow \text{piel} && [0.3] \\
\textit{Sustantivo} &\rightarrow \text{pelo} && [0.1] \\
&\ldots
\end{aligned}
$$

Gramáticas libres de contexto probabilísticas

Una GLCP nos da una definición de probabilidad de una oración S, como la suma de las probabilidades de sus árboles de parsing posibles:

$$P(S) = \sum_{T:parsing(S)} P(T)$$

Entonces, podemos usar una GLPC como un modelo del lenguaje, algo muy útil en reconocimiento del habla, traducción automática, corrección de ortografía, detección de idioma, y muchas otras tareas de Procesamiento del Lenguaje Natural (PLN).

Ejemplo: ¿Es más probable que el usuario haya dicho *"una moneda de cincuenta centavos"* o *"una manera de cincuenta centauros"*?