Inteligencia Artificial y Neurociencias

Licenciatura en Tecnología Digital, UTDT, 2S-2026

Profesores: Agustín Gravano, Andrés Rieznik
Auxiliares: Gerardo Del Toro, Antonella Giordano Furchi

Modelado Computacional del Lenguaje

La jueza actuante, Dra. Juana Pérez, le dijo al abogado querellante que debería presentar todas las pruebas contra el banco antes del 11 de noviembre del corriente año. En caso contrario, se encontraría imposibilitada de continuar.

Algunas tareas y aplicaciones de Procesamiento del Lenguaje Natural

- Análisis morfológico: tokenización, normalización
- Etiquetado de clases de palabras (POS tagging)
- Segmentación (en frases, oraciones)
- Parsing / análisis sintáctico
- Desambiguación léxica (WSD)
- Etiquetado de roles semánticos
- Resolución de referencias
- Reconocimiento de entidades nombradas (NER)
- Análisis de sentimiento
- Recuperación de información
- Traducción automática
- Corrección ortográfica y gramatical
- Identificación de enfermedades, genes, etc. en papers médicos
- Extracción de entidades y relaciones en textos legales
- Anonimización de documentos
- Monitoreo de marcas, personas, etc. en redes y medios
- Análisis de reviews de productos
- Filtros de spam
- Moderación de contenido
- Clasificación de tickets de soporte
- Detección de noticias falsas
- Subtitulado automático
- Indicadores de mercado basados en noticias financieras
- ...

Racionalismo (Teorías)

Empiricismo (Datos)



La razón humana es la fuente principal y más confiable de conocimiento

El conocimiento proviene principalmente de la experiencia sensorial

Evolución histórica del Procesamiento del Lenguaje Natural

Período (aprox.)	**Paradigma**	**Ejemplos de técnicas**
hasta 2000	Simbólico	Reglas, diccionarios, expresiones regulares, GLC
2000 – 2013	Estadístico	n-gramas, GLCP, Naive Bayes, SVM, RF, HMM
2013 – 2018	Neuronal	RNN, CNN, LSTM
2018 – hoy	Transformers	GPT, BERT, BART

Tokenización: ¿qué es una palabra?

¿Cuántas palabras tiene esta oración?

"El Dr. Gómez cobró $1.250,00 el 09/12 por el análisis de ADN."

Casos problemáticos: abreviaturas *(Dr.)*, siglas *(ADN)*, contracciones *(al, del)*, expresiones numéricas, fechas, emojis :-), #hashtags, @menciones, etc.

Normalización

Problema: la misma unidad léxica aparece bajo muchas formas.

correr, corro, corrió, corriendo, correrá → Queremos tratarlas como una sola.

Dos enfoques:

- Stemming: Corte heurístico del final de la palabra. Ejemplo: *corr*. Rápido, inexacto, basado en reglas.
- Lematización: Reducción a la forma canónica de diccionario. Ejemplo: *correr*. Requiere conocimiento de la morfología del lenguaje.

—

Morfología: Estudia la estructura interna de las palabras; cómo se forman y modifican.

Morfema: unidad básica con significado. Hay dos tipos: raíces y afijos (prefijos, sufijos, etc.)

Procesos de formación de palabras:

- Flexión: agrega información gramatical (*gat-a-s*, *cant-á-ba-mos*)
- Derivación: cambia el significado (*cuchillo* → *cuchillada*)
- Composición: junta 2+ raíces (*medianoche, telaraña, correveidile*)

Reconocimiento de Entidades Nombradas (NER)

Identificación y clasificación en textos no estructurados de menciones a entidades del mundo real: personas, organizaciones, lugares, expresiones de tiempo o de cantidad, etc.

Una misma entidad puede aparecer varias veces y de formas distintas *(“Dra. Juana Pérez”, “la jueza”, “ella”)*.

No se busca identificar cualquier sustantivo, sino entidades específicas.

Categorías estándar: PER personas / ORG organizaciones / LOC lugares / MISC miscelánea.

En dominios específicos se agregan: leyes, medicamentos, genes, etc.

Part-of-speech (POS) tagging

- Hay palabras que exhiben comportamiento parecido:
  - Aparecen en contextos similares.
  - Desempeñan funciones similares en la oración.
  - Sufren transformaciones similares.
- Clases de palabras:
  - sustantivo — *silla, parlante, bajo*
  - verbo — *estar, estoy, comprendería, bajo*
  - adjetivo — *púrpura, altas, ridículo, parlante, bajo*
  - adverbio — *desafortunadamente, despacio, bajo*
  - preposición — *de, por, a, bajo*
  - pronombre — *yo, mi, mío*
  - determinante — *el, un, ese, estas*
  - conjunción — *y, o, ni, sino*
  - ...

Part-of-speech (POS) tagging

- POS Tagging: Proceso de asignar una etiqueta de clase de palabra (POS) a cada palabra de un texto.

El	***informe***	***dice***	***que***	***no***	***hay***	***evidencia***
Det	Sust	Verbo	Conj	Adv	Verbo	Sust

- ¡No es un mapeo directo!
  - *La compra se concretó.* *la* = artículo *compra* = sust
  - *La compra con crédito.* *la* = pronombre *compra* = verbo
  - Ejemplo en inglés: *Time flies like an arrow.*
    Time [VB,NN] flies [VB,NN] like [VB,PR] an DT arrow NN

POS tagset

- Conjunto de rótulos/etiquetas.
- Podríamos elegir un conjunto reducido:
  - N, V, Adj, Adv, Otros.
- Brown Corpus: 1M palabras, 87 tags
  - Más informativo, pero más difícil de etiquetar.
- Penn Treebank: corpus del Wall Street Journal, 1M palabras, 46 tags
  - El más usado en la actualidad para el inglés.
- Ejemplo para el español: EAGLE tagset
  - https://freeling-user-manual.readthedocs.io/en/latest/tagsets/

Penn Treebank Tagset

Tag	Description	Example	Tag	Description	Example
CC	Coordin. Conjunction	*and, but, or*	SYM	Symbol	+,%, &
CD	Cardinal number	*one, two, three*	TO	"to"	*to*
DT	Determiner	*a, the*	UH	Interjection	*ah, oops*
EX	Existential 'there'	*there*	VB	Verb, base form	*eat*
FW	Foreign word	*mea culpa*	VBD	Verb, past tense	*ate*
IN	Preposition/sub-conj	*of, in, by*	VBG	Verb, gerund	*eating*
JJ	Adjective	*yellow*	VBN	Verb, past participle	*eaten*
JJR	Adj., comparative	*bigger*	VBP	Verb, non-3sg pres	*eat*
JJS	Adj., superlative	*wildest*	VBZ	Verb, 3sg pres	*eats*
LS	List item marker	*1, 2, One*	WDT	Wh-determiner	*which, that*
MD	Modal	*can, should*	WP	Wh-pronoun	*what, who*
NN	Noun, sing. or mass	*llama*	WP$	Possessive wh-	*whose*
NNS	Noun, plural	*llamas*	WRB	Wh-adverb	*how, where*
NNP	Proper noun, singular	*IBM*	$	Dollar sign	*$*
NNPS	Proper noun, plural	*Carolinas*	#	Pound sign	#
PDT	Predeterminer	*all, both*	"	Left quote	(' or ")
POS	Possessive ending	*'s*	"	Right quote	(' or ")
PRP	Personal pronoun	*I, you, he*	(	Left parenthesis	([, (, {, <)
PRP$	Possessive pronoun	*your, one's*	)	Right parenthesis	( ],), }, >)
RB	Adverb	*quickly, never*	,	Comma	,
RBR	Adverb, comparative	*faster*	.	Sentence-final punc	(. ! ?)
RBS	Adverb, superlative	*fastest*	:	Mid-sentence punc	(: ; ... – -)
RP	Particle	*up, off*			

Rule-based POS tagging

Variantes del siguiente algoritmo:

1) Asignar a cada palabra todos sus tags posibles.
2) Usar un conjunto de reglas predefinidas para eliminar tags selectivamente.
3) Iterar hasta que cada palabra tenga exactamente un tag.

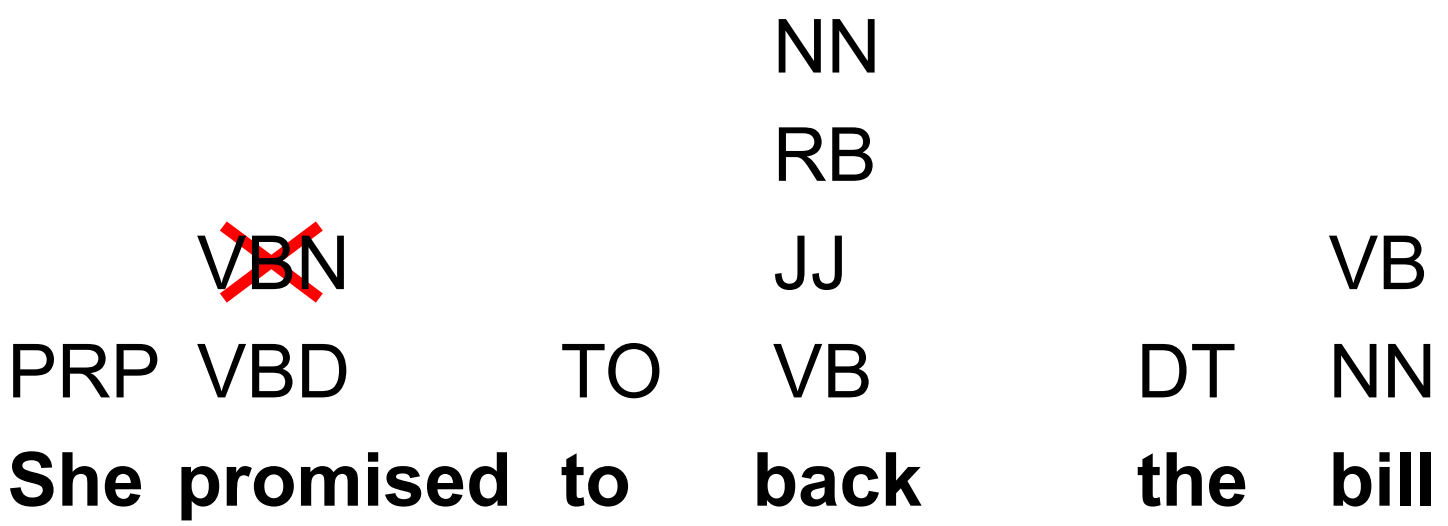
Rule-based POS tagging

			NN		
			RB		
	VBN		JJ		VB
PRP	VBD	TO	VB	DT	NN
She	**promised**	**to**	**back**	**the**	**bill**

Rule-based POS tagging

Regla: Eliminar VBN si VBD es una opción cuando VBN|VBD sucede a "<start> PRP".

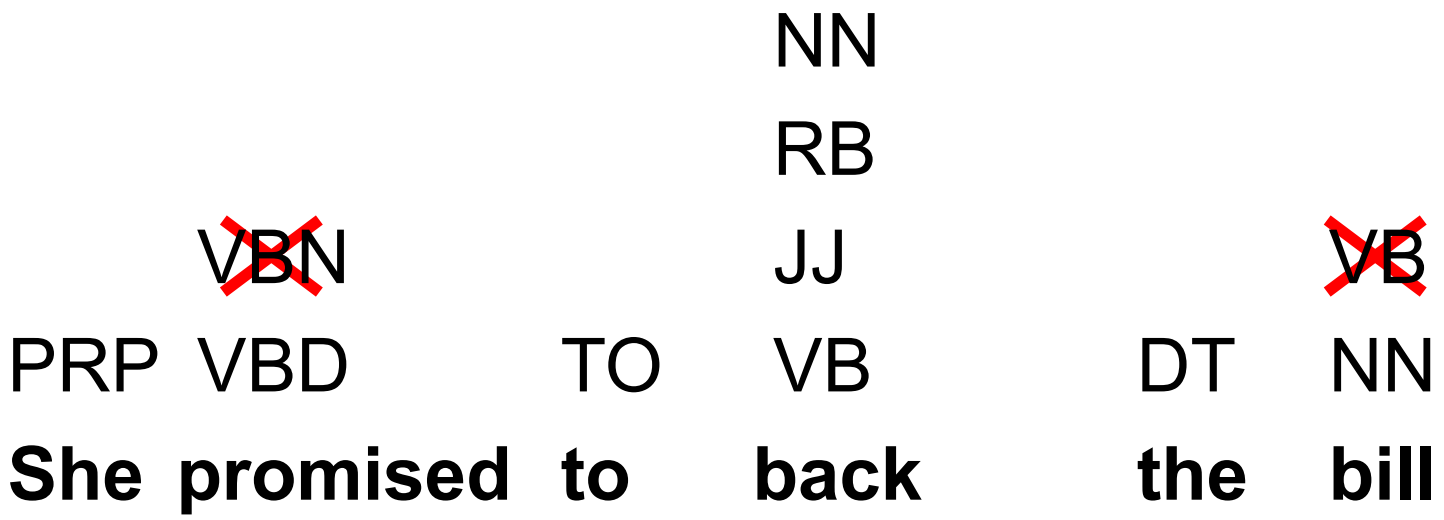
VBN = verb, past participle *VBD = verb, past tense*



Rule-based POS tagging

Regla: Después de DT no puede venir VB (si hay otra opción disponible).

DT = determiner *VB = verb, base form*



Algoritmos de POS tagging

- Rule-based tagging (ej: EnCG ENGTWOL tagger)
- Transformation-based tagging (ej: Brill tagger)
- Enfoques basados en datos:

  Support Vector Machines (SVM), Hidden Markov Models (HMM), Redes recurrentes (RNN), fine-tuned BERT.

- Performance: 95-99%
- Desafíos: habla espontánea, lenguaje informal (*tkm lol*), neologismos, variantes dialectales

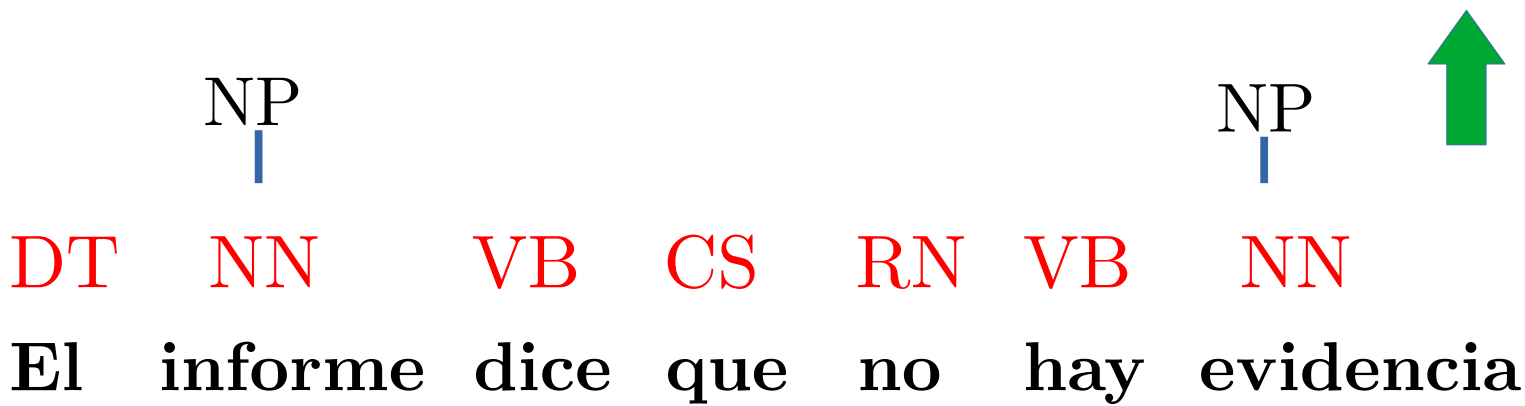
Análisis sintáctico

S → NP VP
NP → DT NP
NP → NN
VP → VB PP
VP → RN VP
VP → VB NP
...

DT	NN	VB	CS	RN	VB	NN
El	**informe**	**dice**	**que**	**no**	**hay**	**evidencia**

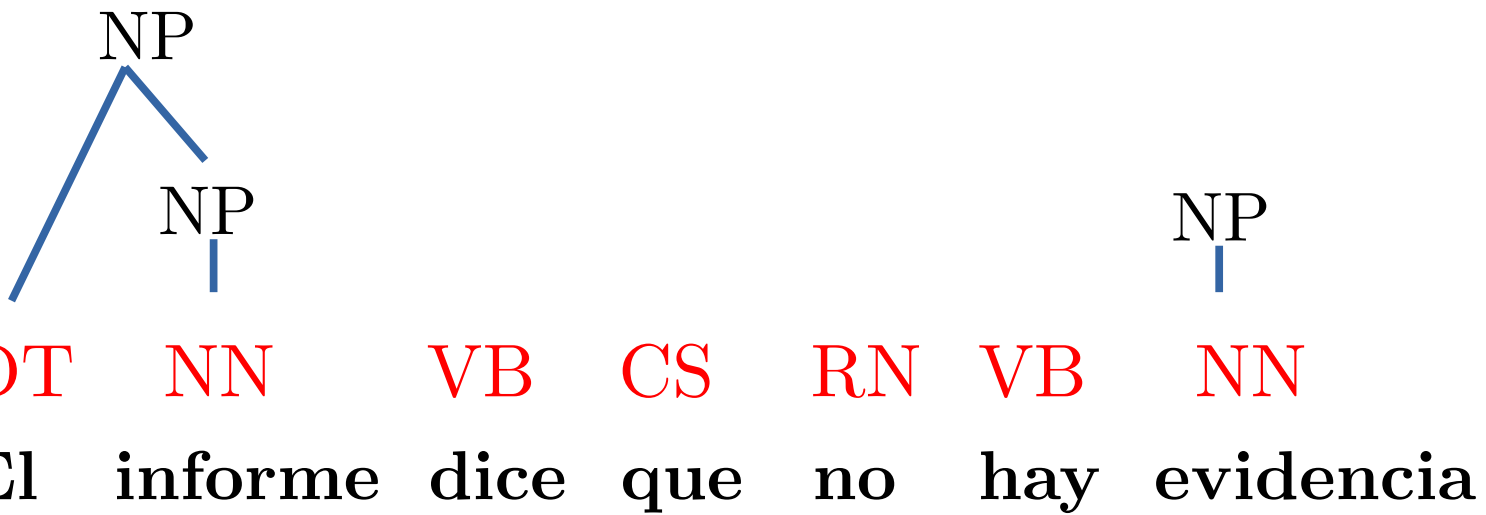
Análisis sintáctico

S → NP VP
NP → DT NP
NP → NN
VP → VB PP
VP → RN VP
VP → VB NP
...



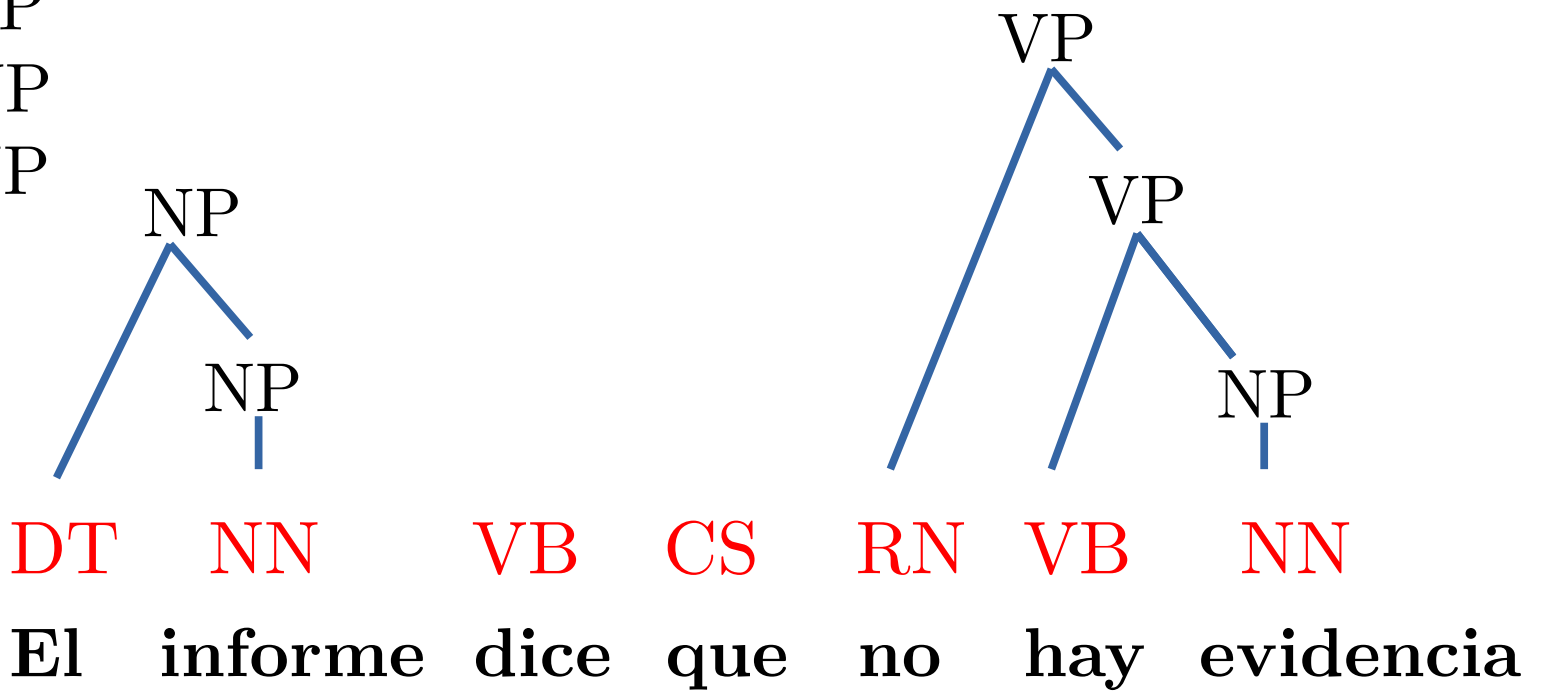
Análisis sintáctico

S → NP VP
NP → DT NP
NP → NN
VP → VB PP
VP → RN VP
VP → VB NP
...



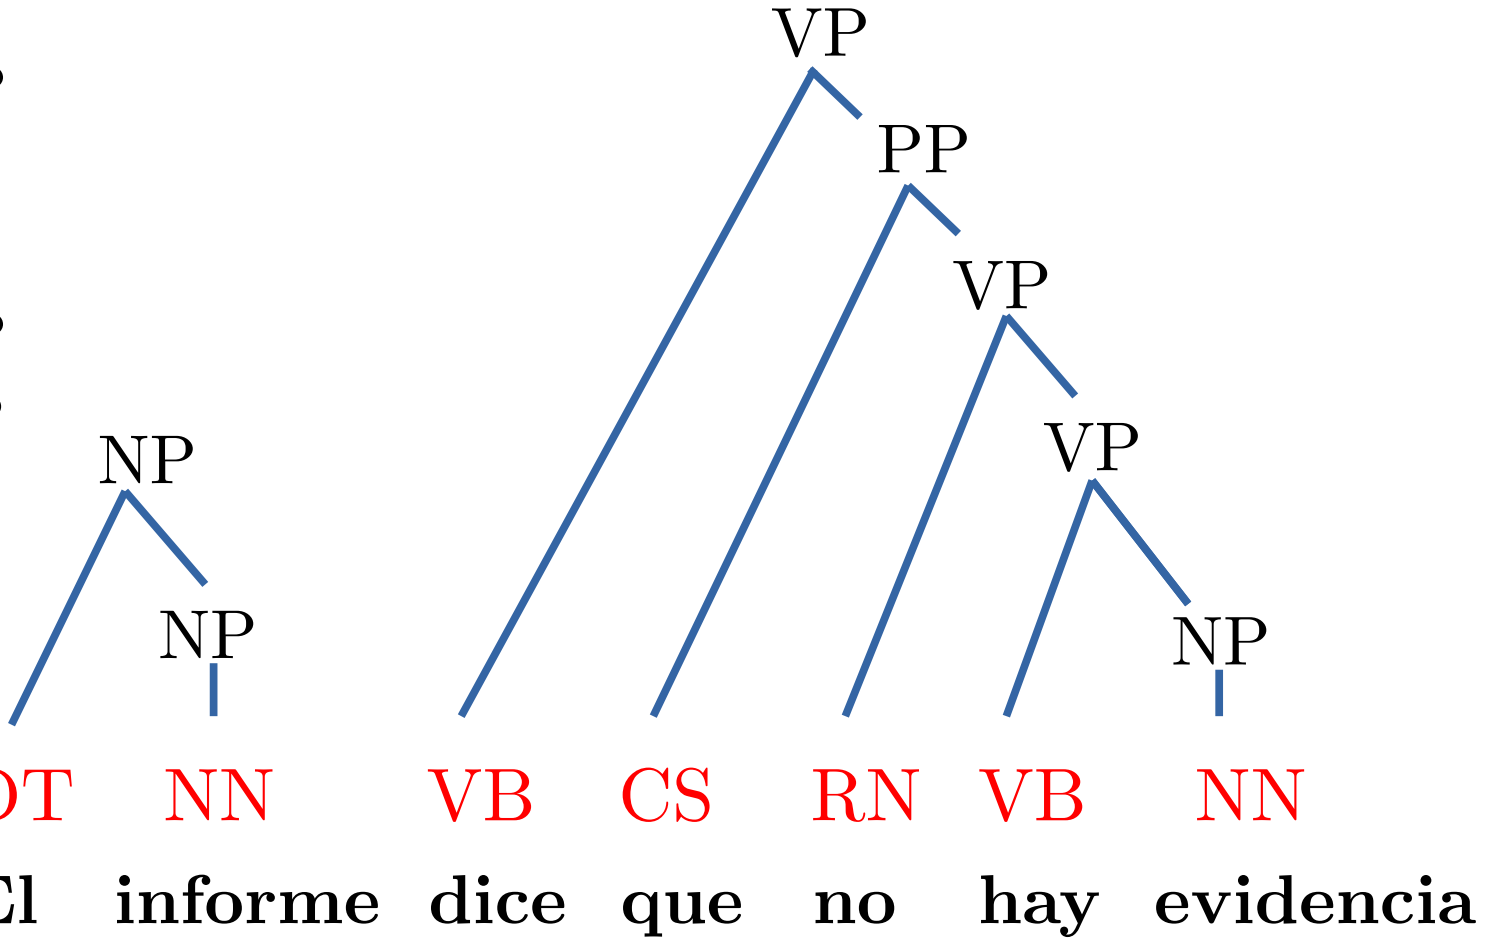
Análisis sintáctico

S → NP VP
NP → DT NP
NP → NN
VP → VB PP
VP → RN VP
VP → VB NP
...



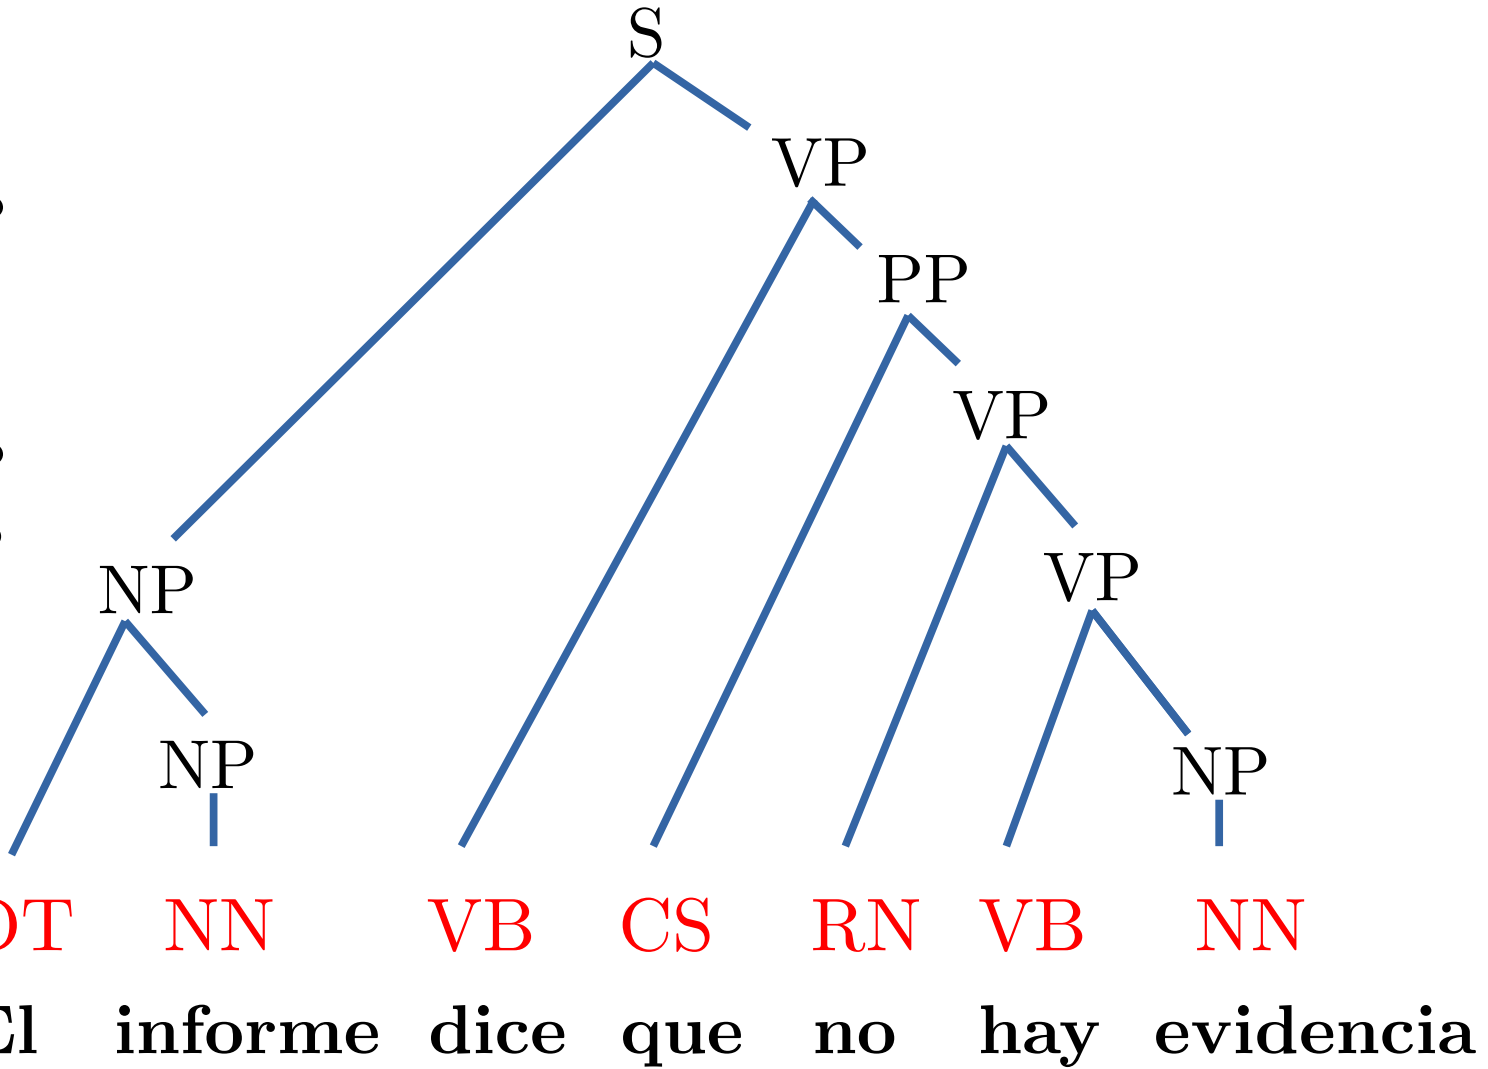
Análisis sintáctico

S → NP VP
NP → DT NP
NP → NN
VP → VB PP
VP → RN VP
VP → VB NP
...



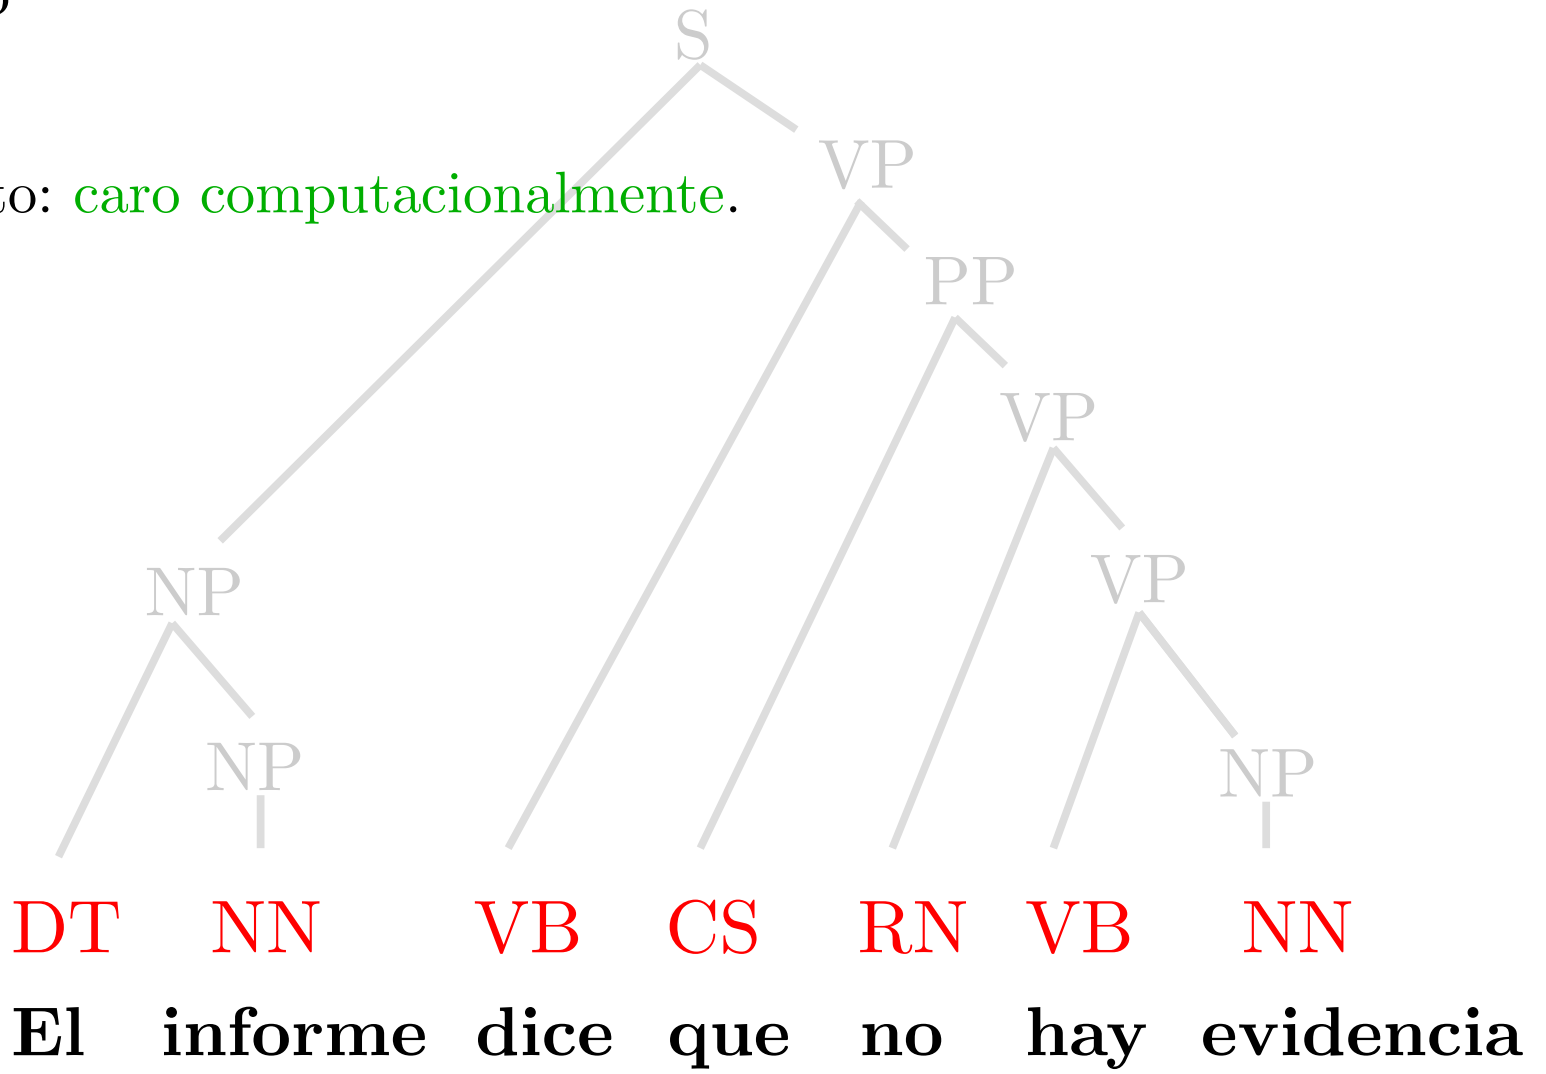
Análisis sintáctico

S → NP VP
NP → DT NP
NP → NN
VP → VB PP
VP → RN VP
VP → VB NP
...



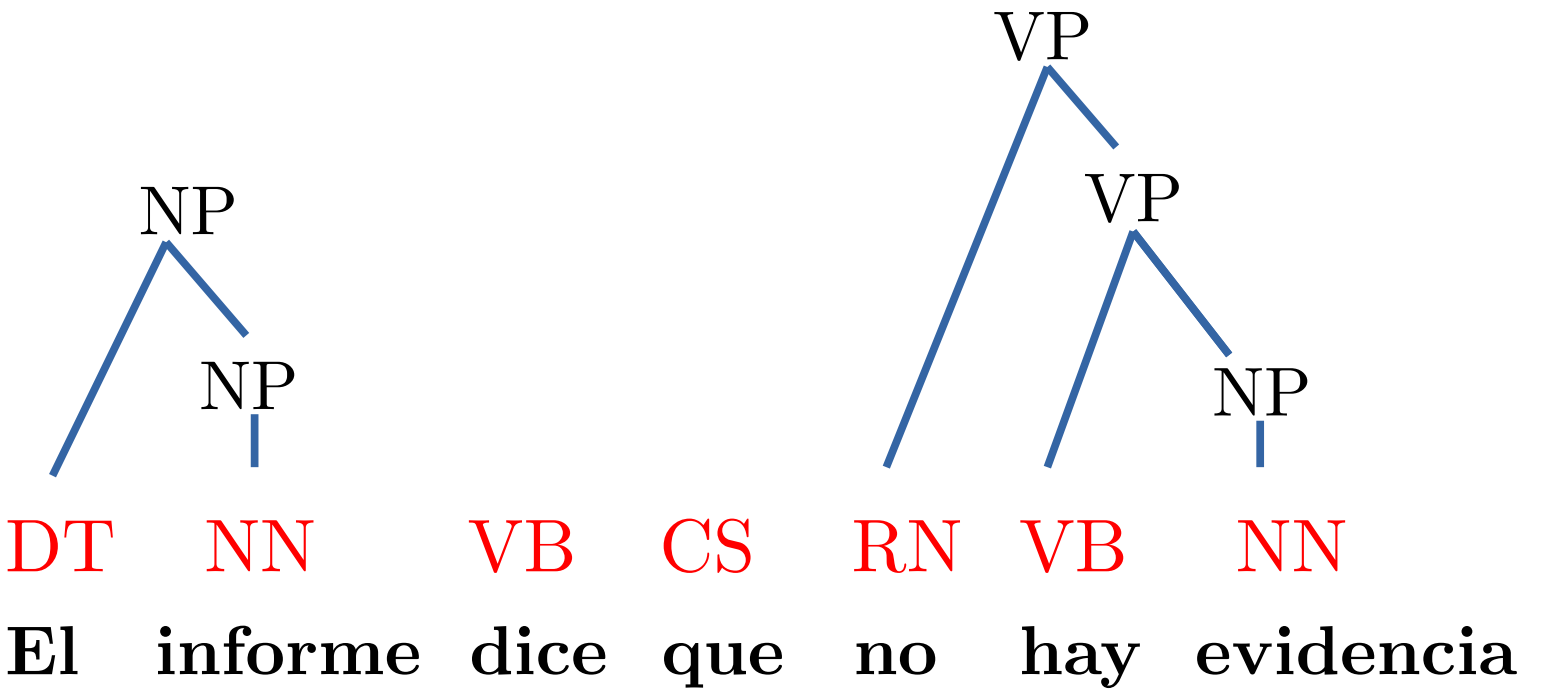
Análisis sintáctico

- Parsing completo: caro computacionalmente.



Análisis sintáctico

- Parsing completo: caro computacionalmente.
- Alternativas: shallow parsing; chunking.



Modelos de Lenguaje

Modelos de Lenguaje

Problema: En muchas aplicaciones, el sistema genera múltiples hipótesis y necesita elegir la más plausible.

Un modelo de lenguaje provee una medida de cuán probable es una secuencia de palabras.

$$P(el\ gato\ come\ pescado) > P(pescado\ come\ gato\ el)$$

Aplicaciones clásicas:

- Reconocimiento automático del habla (ASR)
- Traducción automática
- Corrección ortográfica y gramatical
- Predicción de texto

Gramáticas libres de contexto probabilísticas

Una GLC probabilística es una tupla $(V,\ T,\ P,\ S)$.

Todas las producciones en P tienen la forma A $\rightarrow \alpha\ [p]$, donde $A \in V$, $\alpha \in (V \cup T)^*$, $p \in \mathbb{R}$, $0 \leq p \leq 1$

p es la probabilidad de expandir una variable A mediante una producción: $p = P(A \rightarrow \beta \mid A)$, de modo que $\sum_\beta P(A \rightarrow \beta \mid A) = 1$

Así, es natural hablar de la probabilidad de un parsing:

$P(T) = \prod_{i=1}^{n} P(A_i \rightarrow \beta_i)$, donde $A_i \rightarrow \beta_i$ son las n reglas aplicadas en el árbol de parsing T.

GLC probabilísticas – Ejemplo de juguete

Grammar		Lexicon
$S \rightarrow NP\ VP$	[.80]	$Det \rightarrow that\ [.10] \mid a\ [.30] \mid the\ [.60]$
$S \rightarrow Aux\ NP\ VP$	[.15]	$Noun \rightarrow book\ [.10] \mid flight\ [.30]$
$S \rightarrow VP$	[.05]	$\mid meal\ [.15] \mid money\ [.05]$
$NP \rightarrow Pronoun$	[.35]	$\mid flights\ [.40] \mid dinner\ [.10]$
$NP \rightarrow Proper\text{-}Noun$	[.30]	$Verb \rightarrow book\ [.30] \mid include\ [.30]$
$NP \rightarrow Det\ Nominal$	[.20]	$\mid prefer;[.40]$
$NP \rightarrow Nominal$	[.15]	$Pronoun \rightarrow I\ [.40] \mid she\ [.05]$
$Nominal \rightarrow Noun$	[.75]	$\mid me\ [.15] \mid you\ [.40]$
$Nominal \rightarrow Nominal\ Noun$	[.20]	$Proper\text{-}Noun \rightarrow Houston\ [.60]$
$Nominal \rightarrow Nominal\ PP$	[.05]	$\mid NWA\ [.40]$
$VP \rightarrow Verb$	[.35]	$Aux \rightarrow does\ [.60] \mid can\ [40]$
$VP \rightarrow Verb\ NP$	[.20]	$Preposition \rightarrow from\ [.30] \mid to\ [.30]$
$VP \rightarrow Verb\ NP\ PP$	[.10]	$\mid on\ [.20] \mid near\ [.15]$
$VP \rightarrow Verb\ PP$	[.15]	$\mid through\ [.05]$
$VP \rightarrow Verb\ NP\ NP$	[.05]	
$VP \rightarrow VP\ PP$	[.15]	
$PP \rightarrow Preposition\ NP$	[1.0]	

Figure 14.1 A PCFG which is a probabilistic augmentation of the $\mathscr{L}_1$ miniature English CFG grammar and lexicon of Fig. 13.1 in Ch. 13. These probabilities were made up for pedagogical purposes and are not based on a corpus (since any real corpus would have many more rules, and so the true probabilities of each rule would be much smaller).

Tomado de: Jurafsky & Martin, "Speech and Language Processing", Pearson, 2nd ed (2009), p495.

Gramáticas libres de contexto probabilísticas

Una GLCP nos da una definición de probabilidad de una oración S, como la suma de las probabilidades de sus árboles de parsing posibles:

$$P(S) = \sum_{T:\text{parsing}(S)} P(T)$$

Entonces, podemos usar una GLPC como un modelo del lenguaje, algo muy útil en reconocimiento del habla, traducción automática, corrección de ortografía, detección de idioma, y muchas otras tareas de PLN.

Ejemplo: ¿es más probable que el usuario haya dicho *"una moneda de cincuenta centavos"* o *"una manera de cincuenta centauros"*?

Predicción de palabras

Messi metió dos ___???___

Está abierto de lunes a ___???___

Ayer el precio del Bitcoin ___???___

La gruá llevó el auto al ___???___

Predicción de palabras

En alguna medida, es posible predecir palabras futuras en una oración.

¿Cómo hacemos los seres humanos?

- Conocimiento **léxico**: palabras
- Conocimiento **sintáctico**: estructura
- Conocimiento **semántico**: significados
- **Conocimiento del mundo**

N-gramas

Otra forma de estimar la probabilidad de una oración

Usando la regla de la cadena, $P(A \wedge B) = P(A \mid B) \cdot P(B)$, tenemos que:

$$\begin{aligned} P(w_1 \dots w_m) &= P(w_1) \cdot P(w_2|w_1) \cdot P(w_3|w_1 w_2) \cdot \dots \cdot P(w_m|w_1 w_2 \dots w_{m-1}) \\ &= \prod_{k=1}^{m} P(w_k \mid w_1 \dots w_{k-1}) \end{aligned}$$

Ejemplo: $P(\textit{está abierto de lunes a viernes}) =$
$P(\textit{está}) \cdot P(\textit{abierto} \mid \textit{está}) \cdot P(\textit{de} \mid \textit{está abierto}) \cdot$
$P(\textit{lunes} \mid \textit{está abierto de}) \cdot P(\textit{a} \mid \textit{está abierto de lunes}) \cdot$
$P(\textit{viernes} \mid \textit{está abierto de lunes a})$

N-gramas

Suposición de Markov: La probabilidad de una palabra depende solamente de las N–1 palabras anteriores (N-grama).

$$P\big(w_m \,|\, w_1 \ldots w_{m-1}\big) \approx P\big(w_m \,|\, w_{m-(N-1)} \ldots w_{m-2}\, w_{m-1}\big)$$

N=2: bigrama

$$P\big(w_m \,|\, w_1 \ldots w_{m-1}\big) \approx P\big(w_m \,|\, w_{m-1}\big)$$

$$P(\textit{viernes} \mid \textit{está abierto de lunes a}) \approx P(\textit{viernes} \mid \textit{a})$$

N=3: trigrama

$$P\big(w_m \,|\, w_1 \ldots w_{m-1}\big) \approx P\big(w_m \,|\, w_{m-2}\, w_{m-1}\big)$$

$$P(\textit{viernes} \mid \textit{está abierto de lunes a}) \approx P(\textit{viernes} \mid \textit{lunes a})$$

N-gramas

Estimar la probabilidad de una oración con bigramas (N=2):

$$P(\textit{está abierto de lunes a viernes}) \approx$$
$$P(\textit{está} \mid \textit{<start>}) \cdot P(\textit{abierto} \mid \textit{está}) \cdot P(\textit{de} \mid \textit{abierto}) \cdot$$
$$P(\textit{lunes} \mid \textit{de}) \cdot P(\textit{a} \mid \textit{lunes}) \cdot P(\textit{viernes} \mid \textit{a}) \cdot P(\textit{<end>} \mid \textit{viernes})$$

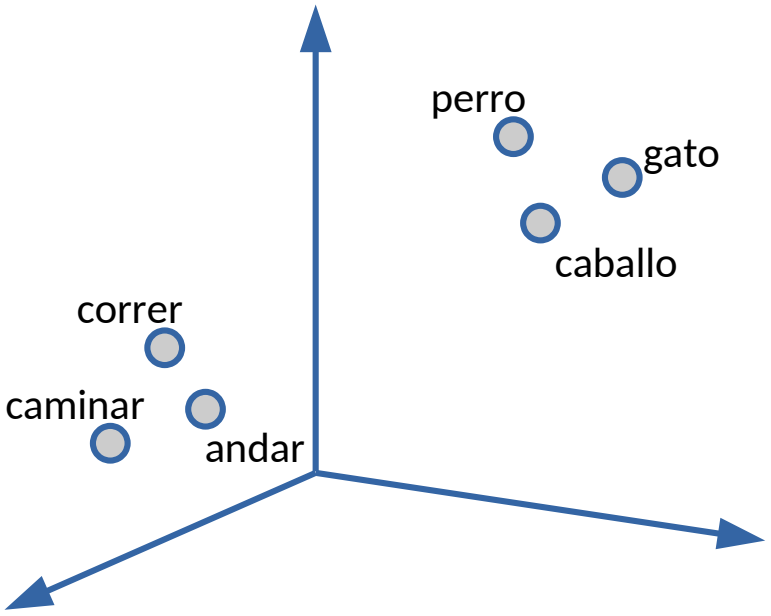
¿Qué necesitamos para hacer estos cálculos?

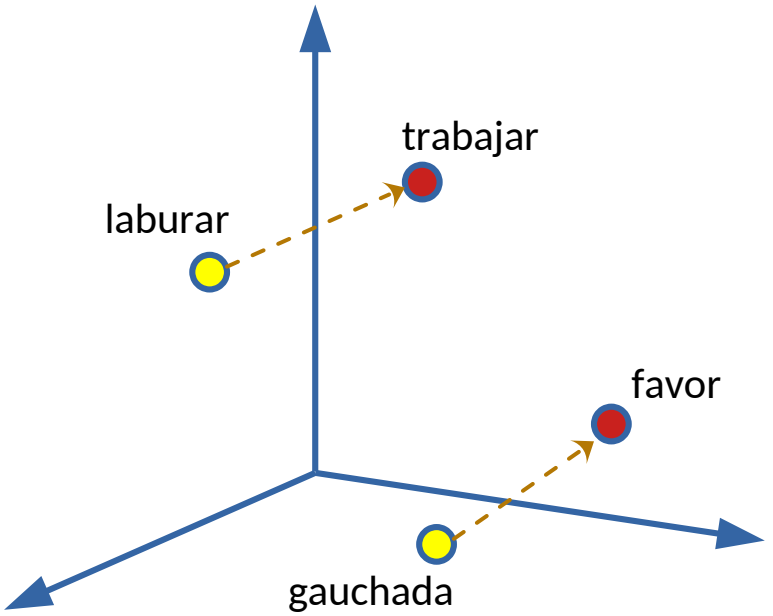
Estimamos $P(w_m \mid w_{m-1})$ usando las frecuencias de palabras y pares de palabras, pre-calculadas en un corpus grande:

$$P(\textit{abierto} \mid \textit{está}) \approx \#(\textit{está abierto}) \ / \ \#(\textit{está})$$

Semántica Vectorial

Representación de textos: de símbolos a vectores





Representación de textos: de símbolos a vectores

Hipótesis distribucional: las palabras que se usan en contextos similares suelen tener significados similares (Joos 1950, Harris 1954, Firth 1957)

Representación de textos: de símbolos a vectores

Hipótesis distribucional: las palabras que se usan en contextos similares suelen tener significados similares (Joos 1950, Harris 1954, Firth 1957)

Hubo sucesivos intentos, cada vez más sofisticados, de representar el significado de palabras y documentos como **vectores**.

- Matriz documento-término *(Bag of Words)*
- TF-IDF (Term Frequency–Inverse Document Frequency)
- PMI (Pointwise Mutual Information)
- LSA (Latent Semantic Analysis)
- LDA (Latent Dirichlet Allocation)
- Word embeddings (Word2Vec, GloVe)
- Embeddings contextuales (ELMo, BERT)

	w1	w2	w3	w4	w5	…
d1	4	0	0	0	1	
d2	0	1	7	0	0	
d3	0	5	0	3	0	
d4	3	0	8	0	1	
d5	0	2	1	0	2	
…						

Representación de textos: de símbolos a vectores

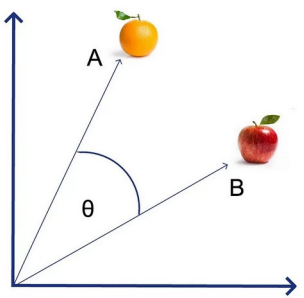
Hipótesis distribucional: las palabras que se usan en contextos similares suelen tener significados similares (Joos 1950, Harris 1954, Firth 1957)

Hubo sucesivos intentos, cada vez más sofisticados, de representar el significado de palabras y documentos como **vectores**.

- Matriz documento-término *(Bag of Words)*
- TF-IDF (Term Frequency–Inverse Document Frequency)
- PMI (Pointwise Mutual Information)
- LSA (Latent Semantic Analysis)
- LDA (Latent Dirichlet Allocation)
- Word embeddings (Word2Vec, GloVe)
- Embeddings contextuales (ELMo, BERT)

	w1	w2	w3	w4	w5	...
d1	4	0	0	0	1	
d2	0	1	7	0	0	
d3	0	5	0	3	0	
d4	3	0	8	0	1	
d5	0	2	1	0	2	
...						

Similitud coseno para comparar vectores:

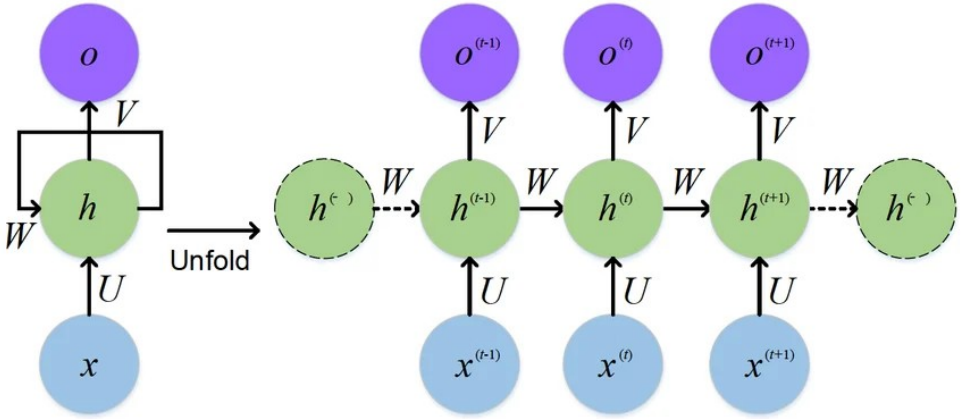


$$sim(A, B) = \cos(\theta) = \frac{A \cdot B}{\|A\| \, \|B\|}$$

Modelos Neuronales Recurrentes

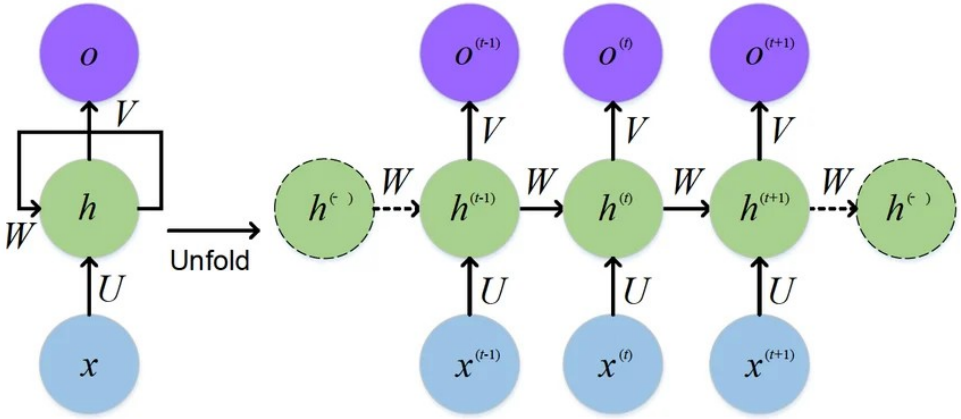
Redes Neuronales Recurrentes (RNN)

- Estado del arte de PLN hasta 2017-18



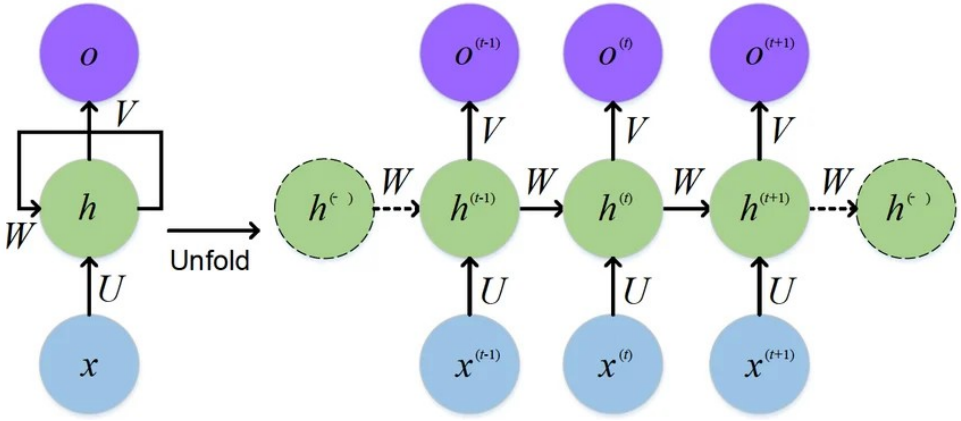
Redes Neuronales Recurrentes (RNN)

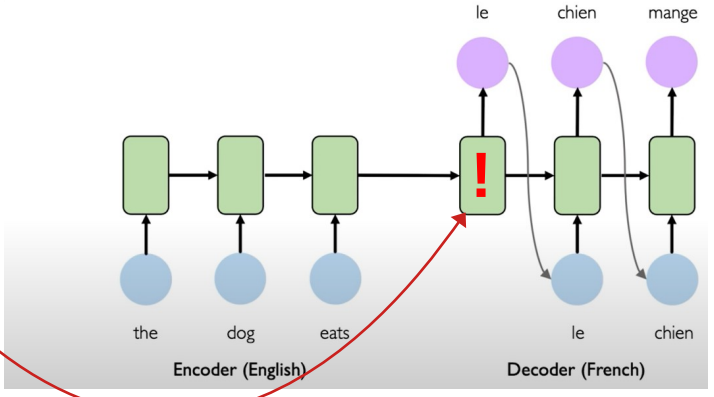
- Estado del arte de PLN hasta 2017-18
- Variantes:
  - Long Short Term Memory (LSTM): solucionó gradiente desvaneciente
  - Gated Recurrent Unit (GRU): agregó mecanismos de atención



Redes Neuronales Recurrentes (RNN)

- Estado del arte de PLN hasta 2017-18
- Variantes:
  - Long Short Term Memory (LSTM): solucionó gradiente desvaneciente
  - Gated Recurrent Unit (GRU): agregó mecanismos de atención
- Problemas: secuencialidad (un token por vez), dependencias largas, cuello de botella en seq2seq





"la profesora que diseñó el plan de estudios de la nueva carrera de humanidades estaba preocupado"

Procesamiento del Lenguaje Natural

Evolución histórica

Período (aprox.)	**Paradigma**	**Ejemplos de técnicas**
hasta 2000	Simbólico	Reglas, diccionarios, expresiones regulares, GLC
2000 – 2013	Estadístico	n-gramas, GLCP, Naive Bayes, SVM, RF, HMM
2013 – 2018	Neuronal	RNN, CNN, LSTM
2018 – hoy	Transformers	GPT, BERT, BART

Herramientas

- NLTK - `https://www.nltk.org/`
- spaCy - `https://spacy.io/`
- FreeLing - `https://nlp.lsi.upc.edu/freeling/`