

Guía de ejercicios - Aprendizaje por Refuerzo

Inteligencia Artificial y Neurociencias

Segundo semestre de 2026

Bandidos de k brazos

Ejercicio 1. Considerar el problema de bandidos de k brazos, con $k = 4$ acciones, denominadas respectivamente 1, 2, 3, y 4. Se aplicó un algoritmo de bandidos usando selección de acciones ϵ -greedy, estimando el valor de las acciones con el promedio muestral, y usando $\forall a, Q_1(a) = 0$ como estimaciones iniciales. La secuencia inicial de acciones y recompensas es $A_1 = 1, R_1 = -1, A_2 = 2, R_2 = 1, A_3 = 2, R_3 = -2, A_4 = 2, R_4 = 2, A_5 = 3, R_5 = 0$. En algunos de estos pasos, el caso ϵ pudo haber ocurrido, causando que una acción fuera seleccionada al azar. ¿En qué pasos de tiempo seguro ocurrió esto? ¿En qué pasos de tiempo podría haber ocurrido esto?

Ejercicio 2. Exploración con valores iniciales optimistas. Modificar el algoritmo ϵ -greedy, de modo que $\forall a, Q_1(a)$ tome un valor muy alto. Correr una simulación y estudiar las consecuencias de este cambio. Ayuda: Este tema se desarrolla en la sección 2.6 del S&B.

Ejercicio 3.

1. Modificar el algoritmo ϵ -greedy de modo que la acción se seleccione según la siguiente fórmula:

$$A_t \doteq \arg \max_a \left[Q_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right]$$

donde $N_t(a)$ denota la cantidad de veces que la acción a fue seleccionada antes del tiempo t , y c es una constante positiva que controla el grado de exploración.

En el caso en que $N_t(a) = 0$, se considera a a como una de las acciones que maximizan la fórmula.

2. Correr una simulación y comparar este algoritmo contra los otros vistos en clase.

Ayuda: Este tema se desarrolla en la sección 2.7 del S&B.

Ejercicio 4. Sea un problema de bandidos de $k = 10$ brazos, en el cual ejecutaremos 1000 acciones. ¿Usar una política ϵ -greedy con $\epsilon = 0,1$ es equivalente a primero ejecutar 10 veces cada acción y luego ejecutar 900 veces la acción con mayor valor estimado?

Procesos de Decisión de Markov

Ejercicio 5. Supongamos que estamos diseñando un robot que aprenda a escapar de un laberinto. Se decide darle una recompensa de 1 cuando escapa, y 0 en cualquier otro caso. La tarea parece separarse naturalmente en episodios (las sucesivas recorridas por el laberinto) donde se busca maximizar la recompensa esperada total. Luego de muchas corridas, se observa que el agente no muestra ninguna mejora. ¿Qué está ocurriendo? ¿Está configurado correctamente el objetivo del agente?

Ejercicio 6. Dada la siguiente secuencia de recompensas $R_1 = -1, R_2 = 2, R_3 = 6, R_4 = 3$, y $R_5 = 2$ con $T = 5$. Si suponemos $\gamma = 0,5$, ¿Cuáles son $G_0, G_1, \dots, G_4$? Ayuda: Resolver el problema desde el final hacia el principio.


Ejercicio 7. Suponer $\gamma = 0,9$ y la secuencia de recompensas es $R_1 = 2$ seguido de una secuencia infinita de siete ($R_2 = 7, R_3 = 7, \dots$). ¿Qué valores toman G_0 y G_1 ?

Ejercicio 8. Demostrar que si $\forall t, R_t = 1$, entonces $G_t = \frac{1}{(1-\gamma)}$.

Ejercicio 9. Sea $p(s'|s, a)$ la probabilidad de llegar al estado s' al ejecutar la acción a en el estado s . Expresar $p(s'|s, a)$ en base a $p(s', r|s, a)$.

Ejercicio 10. Sea $r(s, a)$ la recompensa esperada al ejecutar la acción a en el estado s . Expresar $r(s, a)$ en base a $p(s', r|s, a)$.

Ejercicio 11. Considerar el siguiente ambiente determinístico de 6 estados, con las transiciones y las recompensas indicadas:



A es el estado inicial, F es terminal, y sea la política determinística $\pi: \{A \rightarrow B, B \rightarrow C, C \rightarrow F, D \rightarrow E, E \rightarrow F\}$. Para cada uno de estos valores de descuento γ : 0, 0,5 y 1, se pide calcular manualmente v_π (el valor de cada estado según π) y q_π (el valor de cada par estado-acción según π).

Ejercicio 12. En el juego “Cuatro en línea”, ¿la función $p(s', r|s, a)$ que caracteriza el ambiente es estocástica o determinística? Justificar.

Métodos Monte Carlo

Ejercicio 13. Sea un ambiente con estados $\{s_1, s_2, s_3, s_4\}$ y acciones $\{izq, der\}$. Las dos acciones están disponibles en todos los estados menos en s_4 , que es terminal. Se ejecuta el algoritmo Monte Carlo para estimar π^* visto en clase, con descuento $\gamma = 1$. $Q(s, a)$ se inicializa con ceros. Se generan los siguientes episodios:

Episodio 1: $s_1, der, +1, s_2, der, +1, s_3, izq, +1, s_2, der, +1, s_3, der, +4, s_4$

Episodio 2: $s_1, der, +1, s_2, der, +1, s_3, der, +4, s_4$

1. ¿Cómo quedan actualizados $Retornos(S, A)$ y $Q(S, A)$, para cada estado y acción, al final de cada episodio?
2. ¿Cuál es la acción *greedy* en cada estado al comenzar el tercer episodio?

Ejercicio 14. Sea un ambiente con estados $\{s_1, s_2, s_3\}$ y acciones $\{a, b\}$. Las dos acciones están disponibles solamente en s_1 . Los otros dos estados son terminales. Se ejecuta el algoritmo Monte Carlo para estimar π^* , con descuento $\gamma = 1$. Luego de dos iteraciones, sabemos que:

$$Retornos(s_1, a) = [8, 2]$$

$$Retornos(s_1, b) = [10]$$

Si $\epsilon = 0,1$, ¿cuál es la probabilidad de observar a continuación el episodio s_1, a, r, s_2 , para algún valor de recompensa r ? ¿Y el episodio s_1, b, r, s_2 ?

Ejercicio 15. El algoritmo Monte Carlo para estimar π^* visto en clase es ineficiente por dos motivos:

1. Mantiene una lista de retornos cada par estado-acción y recomputa las medias en cada iteración. Sería más eficiente usar una técnica de actualización incremental similar a la que usa bandidos de k brazos, para así ahorrar tiempo y espacio.
2. Al recorrer cada episodio de izquierda a derecha ($t = 0, 1, \dots, T - 1$), el cálculo de G en cada iteración requiere una sumatoria. Sería más eficiente recorrer el episodio de derecha a izquierda ($t = T - 1, T - 2, \dots, 0$), actualizando incrementalmente el valor de G en cada iteración.

Reescribir el algoritmo con esas dos modificaciones. ¿Cómo mejoró su complejidad temporal?

Ejercicio 16. ¿Cuál sería el efecto de ejecutar el algoritmo Monte Carlo para estimar π^* , inicialmente con un valor alto de ϵ (p.ej.: 1), que se va disminuyendo gradualmente hasta llegar a un valor bajo (p.ej.: 0,01)?

Métodos de Diferencias Temporales

Ejercicio 17. Considerar el ejemplo visto en clase, que ilustra la aplicación del algoritmo Monte Carlo en un juego de BlackJack (sin ases). Suponer que inicialmente $Q(s, a) = 0, \forall s, a$, y que el agente ejecuta los mismos tres episodios dados en el ejemplo. Hacer un seguimiento manual de las sucesivas actualizaciones de Q , según el algoritmo SARSA y según Q-Learning, con $\gamma = 1$ y $\alpha = 0,5$.

Ejercicio 18. Se está entrenando un agente con un algoritmo TD en cierto ambiente. En un momento dado, la tabla Q tiene estos valores (entre otros): $Q(0, a) = 10$, $Q(1, b) = 10$, $Q(1, c) = -5$ y $Q(1, d) = 0$. El agente está en $S = 0$, ejecuta la acción a y como consecuencia avanza a $S' = 1$ con $R = 5$. Suponiendo $\gamma = 0,9$, $\alpha = 0,8$, $\epsilon = 0,1$.

1. ¿Cómo se actualiza $Q(0, a)$ según SARSA? Considerar todas las opciones en la elección de A' (explotación y las distintas exploraciones posibles).
2. ¿Cómo se actualiza $Q(0, a)$ según Q-Learning?

Ejercicio 19. Sea un ambiente con estados $\{s_1, s_2\}$ y acciones $\{\leftarrow, \rightarrow\}$, ambas disponibles en ambos estados. La tarea es continua (no termina nunca). Se empieza a ejecutar Q-learning con tasa de aprendizaje $\alpha = 0,1$, factor de descuento $\gamma = 0,5$, y con la tabla $Q(s, a)$ inicializada en 0 para todo estado s y acción a . La trayectoria del agente comienza así:

$$s_1, \rightarrow, +100, s_2, \rightarrow, +300, s_2, \leftarrow, +195, s_1, \rightarrow, +95, s_2, \dots$$

1. Hacer un seguimiento manual del algoritmo, mostrando cómo se actualiza Q después de ejecutar cada una de las cuatro acciones.
2. ¿Cuál es la política *greedy* según Q después de haber ejecutado las cuatro acciones indicadas en la trayectoria de arriba?

Ejercicio 20. La novedad de los métodos TD sobre MC es que los primeros actualizan Q luego de ejecutar cada acción. Pensar o buscar ejemplos concretos en los cuales este cambio representa una ventaja. (Un ejemplo: en un videojuego con muchos estados y acciones posibles, un agente usando TD puede aprender a tomar decisiones en tiempo real, mientras que MC requeriría completar un juego completo para actualizar los valores de Q .)

Ejercicio 21. En Q-Learning, pensar el efecto de usar valores extremos (0 y 1) para cada uno de los parámetros α , ϵ y γ .

Ejercicio 22. ¿Cuál es la diferencia principal entre los algoritmos tabulares SARSA y Q-learning?