

Modelo de Parcial 1 – Aprendizaje por Refuerzo

Inteligencia Artificial y Neurociencias
Universidad Torcuato Di Tella

Formato. Combina **ejercicios prácticos** (seguimiento manual de algoritmos, cálculo de retornos y valores) con **preguntas de interpretación** sobre las fórmulas y conceptos. Debajo de cada consigna se da una *respuesta posible* a modo de guía.

1. Bandidos de k brazos (práctico)

Se aplica un algoritmo de bandidos de $k = 3$ brazos (acciones 1, 2, 3) con selección ϵ -greedy, estimando los valores con el promedio muestral y con $Q_1(a) = 0$ para toda a . La secuencia de acciones y recompensas es: $A_1=1, R_1=2$; $A_2=2, R_2=-1$; $A_3=1, R_3=1$; $A_4=3, R_4=2$; $A_5=1, R_5=0$. ¿En qué pasos seguro ocurrió el caso ϵ (acción al azar) y en qué pasos podría haber ocurrido?

Respuesta posible. Se calcula $Q_t(a)$ antes de cada paso y se compara la acción tomada con la(s) acción(es) greedy. Si la acción tomada *no* es greedy, seguro fue exploración; si lo es, pudo ser greedy o exploración.

t	$Q_t(1), Q_t(2), Q_t(3)$	greedy	A_t	conclusión
1	(0, 0, 0)	{1, 2, 3}	1	podría (empate)
2	(2, 0, 0)	{1}	2	seguro ϵ
3	(2, -1, 0)	{1}	1	podría
4	(1, 5, -1, 0)	{1}	3	seguro ϵ
5	(1, 5, -1, 2)	{3}	1	seguro ϵ

(Actualizaciones: tras $t=1$, $Q(1)=2$; tras $t=3$, $Q(1)=\frac{2+1}{2}=1,5$; tras $t=4$, $Q(3)=2$.) Entonces: **seguro** en $t = 2, 4, 5$; **podría** en $t = 1, 3$.

2. Bandidos (interpretación)

La regla de actualización incremental puede escribirse como $\text{NuevaEst} = \text{ViejaEst} + \text{TasaApr} [\text{Objetivo} - \text{ViejaEst}]$. Identifique qué es cada término en el caso del promedio muestral ($Q_{n+1} = Q_n + \frac{1}{n}[R_n - Q_n]$) y explique por qué en problemas no estacionarios conviene usar una tasa α constante en vez de $\frac{1}{n}$.

Respuesta posible. **ViejaEst** es Q_n (la estimación previa del valor de la acción), **NuevaEst** es Q_{n+1} , el **Objetivo** es la recompensa recién observada R_n , y la **TasaApr** es $\frac{1}{n}$. El término $[R_n - Q_n]$ es el *error de estimación*: la actualización mueve la estimación una fracción de ese error hacia el objetivo.

Con $\frac{1}{n}$, la tasa decrece con el tiempo y todas las recompensas pesan igual (promedio muestral), lo que converge al valor real *si* el valor no cambia. Pero si el problema es **no estacionario** (los valores $q_*(a)$ varían en el tiempo), interesa dar **más peso a las recompensas recientes**. Con α constante, $Q_{n+1} = (1 - \alpha)Q_1 + \sum_{i=1}^n \alpha(1 - \alpha)^{n-i} R_i$: los pesos de las recompensas viejas decaen exponencialmente, así la estimación “olvida” el pasado y sigue los cambios del ambiente.

3. MDP: retornos (práctico)

Dada la secuencia de recompensas $R_1=2, R_2=0, R_3=-1, R_4=3, R_5=1$ con $T = 5$ y $\gamma = 0,5$, calcular $G_0, G_1, \dots, G_4$. **Ayuda:** de atrás hacia adelante usando $G_t = R_{t+1} + \gamma G_{t+1}$.

Respuesta posible. Con $G_5 = 0$:

$$\begin{aligned} G_4 &= R_5 + \gamma G_5 = 1 + 0,5 \cdot 0 = 1 \\ G_3 &= R_4 + \gamma G_4 = 3 + 0,5 \cdot 1 = 3,5 \\ G_2 &= R_3 + \gamma G_3 = -1 + 0,5 \cdot 3,5 = 0,75 \\ G_1 &= R_2 + \gamma G_2 = 0 + 0,5 \cdot 0,75 = 0,375 \\ G_0 &= R_1 + \gamma G_1 = 2 + 0,5 \cdot 0,375 = 2,1875 \end{aligned}$$

4. MDP (interpretación)

Explique qué representa el factor de descuento γ en $G_t = \sum_{k=t+1}^T \gamma^{k-t-1} R_k$. ¿Qué comportamiento induce $\gamma = 0$ y qué comportamiento induce $\gamma \rightarrow 1$? Enuncie además la propiedad de Markov.

Respuesta posible. $\gamma \in [0, 1]$ determina cuánto valora el agente las recompensas futuras frente a las inmediatas. Con $\gamma = 0$ el agente es *miope*: solo le importa la recompensa inmediata R_{t+1} . Con $\gamma \rightarrow 1$ valora casi por igual recompensas lejanas y cercanas (agente “previsor”). Sirve la analogía con la inflación: una inflación alta (que licua el valor del dinero futuro) equivale a un γ bajo.

La **propiedad de Markov** dice que la probabilidad del próximo estado y recompensa depende *solo* del estado y la acción actuales, y no de la historia previa: $p(s', r \mid s, a) = \Pr\{S_t=s', R_t=r \mid S_{t-1}=s, A_{t-1}=a\}$. Esto obliga a definir los estados de modo que incluyan toda la información del pasado relevante para el futuro.

5. Q-learning (práctico)

Ambiente con estados $\{s_1, s_2\}$ y acciones $\{\leftarrow, \rightarrow\}$ (tarea continua). Se ejecuta **Q-learning** con $\alpha = 0,5$, $\gamma = 0,5$ y Q inicializada en 0. La trayectoria es: $s_1, \rightarrow, +4, s_2, \rightarrow, +2, s_1, \rightarrow, +8, s_2, \dots$. Hacer el seguimiento de Q tras cada acción y dar la política greedy resultante.

Respuesta posible. Regla: $Q(S, A) \leftarrow Q(S, A) + \alpha [R + \gamma \max_a Q(S', a) - Q(S, A)]$.

Paso 1 ($s_1, \rightarrow, +4, s_2$): $\max_a Q(s_2, a) = 0$. $Q(s_1, \rightarrow) = 0 + 0,5[4 + 0,5 \cdot 0 - 0] = 2$.

Paso 2 ($s_2, \rightarrow, +2, s_1$): $\max_a Q(s_1, a) = \max(2, 0) = 2$. $Q(s_2, \rightarrow) = 0 + 0,5[2 + 0,5 \cdot 2 - 0] =$

1,5.

Paso 3 ($s_1, \rightarrow, +8, s_2$): $\max_a Q(s_2, a) = \max(1,5, 0) = 1,5$. $Q(s_1, \rightarrow) = 2 + 0,5[8 + 0,5 \cdot 1,5 - 2] = 2 + 0,5 \cdot 6,75 = \mathbf{5,375}$.

Tabla final: $Q(s_1, \rightarrow) = 5,375$, $Q(s_2, \rightarrow) = 1,5$, resto = 0. **Política greedy**: en s_1 elegir $\rightarrow$; en s_2 elegir $\rightarrow$.

6. TD (interpretación)

Escriba las reglas de actualización de SARSA y Q-learning y explique cuál es la única diferencia entre ambas. ¿Por qué se dice que SARSA es *on-policy* y Q-learning *off-policy*?

Respuesta posible.

$$\text{SARSA: } Q(S, A) \leftarrow Q(S, A) + \alpha[R + \gamma Q(S', A') - Q(S, A)]$$

$$\text{Q-learning: } Q(S, A) \leftarrow Q(S, A) + \alpha[R + \gamma \max_a Q(S', a) - Q(S, A)]$$

La única diferencia está en cómo estiman el retorno desde S' : SARSA usa $Q(S', A')$, donde A' es la acción que **realmente** va a tomar según su política ε -greedy; Q-learning usa $\max_a Q(S', a)$, es decir asume una política **greedy pura** para estimar el retorno.

Por eso SARSA es **on-policy**: evalúa y mejora la misma política que usa para actuar (incluye el efecto de la exploración). Q-learning es **off-policy**: la política que estima (greedy) está *desacoplada* de la que sigue para explorar (ε -greedy).