

Modelo de Parcial 3 – Aprendizaje por Refuerzo

Inteligencia Artificial y Neurociencias
Universidad Torcuato Di Tella

Formato. Combina **ejercicios prácticos** (seguimiento manual de algoritmos, cálculo de retornos y valores) con **preguntas de interpretación** sobre las fórmulas y conceptos. Debajo de cada consigna se da una *respuesta posible* a modo de guía. Al final se incluye un *banco de preguntas extra* para practicar.

1. Bandidos: UCB (práctico)

Se usa **selección por límite de confianza superior (UCB)**: $A_t \doteq \arg \max_a [Q_t(a) + c\sqrt{\ln t/N_t(a)}]$, con $c = 1$. Ya se ejecutaron 4 pasos ($t = 5$, $\ln 5 \approx 1,609$) y el estado es $N(1)=2, Q(1)=1$; $N(2)=1, Q(2)=2$; $N(3)=1, Q(3)=0$. ¿Qué acción elige UCB en $t = 5$?

Respuesta posible.

$$\text{UCB}(1) = 1 + \sqrt{1,609/2} = 1 + 0,897 \approx 1,90$$

$$\text{UCB}(2) = 2 + \sqrt{1,609/1} = 2 + 1,269 \approx 3,27$$

$$\text{UCB}(3) = 0 + \sqrt{1,609/1} = 1,269 \approx 1,27$$

El máximo es la **acción 2**. (El término $c\sqrt{\ln t/N_t(a)}$ crece cuando una acción se exploró poco: premia la *incertidumbre*, favoreciendo acciones con pocas visitas.)

2. MDP: retorno infinito (práctico)

(a) Con $\gamma = 0,8$ y la secuencia $R_1 = 3$ seguida de una sucesión infinita de dieces ($R_2 = R_3 = \dots = 10$), calcular G_0 . (b) Demostrar que si $R_t = 1$ para todo t , entonces $G_t = \frac{1}{1-\gamma}$.

Respuesta posible. (a) Desde $t = 1$, la cola es una serie geométrica: $G_1 = \sum_{k=0}^{\infty} 10 \gamma^k = \frac{10}{1-0,8} = 50$. Entonces $G_0 = R_1 + \gamma G_1 = 3 + 0,8 \cdot 50 = \mathbf{43}$.

(b) $G_t = \sum_{k=0}^{\infty} \gamma^k \cdot 1 = 1 + \gamma + \gamma^2 + \dots = \frac{1}{1-\gamma}$ (serie geométrica de razón $\gamma < 1$). Alternativamente, por la forma recursiva $G_t = 1 + \gamma G_t \Rightarrow G_t(1 - \gamma) = 1 \Rightarrow G_t = \frac{1}{1-\gamma}$.

3. SARSA vs Q-learning en una transición (práctico)

La tabla Q tiene: $Q(0, a) = 4$; en el estado 1: $Q(1, x) = 6, Q(1, y) = -2, Q(1, z) = 1$. El agente está en $S = 0$, ejecuta a , recibe $R = 3$ y pasa a $S' = 1$. Con $\gamma = 0,5$ y $\alpha = 0,5$: (a) actualizar $Q(0, a)$ por Q-learning; (b) actualizar $Q(0, a)$ por SARSA considerando todas las opciones de A' (explotación y cada exploración posible).

Respuesta posible. (a) **Q-learning**: usa $\max_a Q(1, a) = 6$.

$$Q(0, a) \leftarrow 4 + 0,5 [3 + 0,5 \cdot 6 - 4] = 4 + 0,5 \cdot 2 = \mathbf{5}.$$

(b) **SARSA**: depende de la acción A' que se elija en $S' = 1$.

- Explotación / exploración que cae en x ($Q = 6$): $4 + 0,5[3 + 0,5 \cdot 6 - 4] = \mathbf{5}$.
- Exploración en y ($Q = -2$): $4 + 0,5[3 + 0,5 \cdot (-2) - 4] = 4 + 0,5 \cdot (-2) = \mathbf{3}$.
- Exploración en z ($Q = 1$): $4 + 0,5[3 + 0,5 \cdot 1 - 4] = 4 + 0,5 \cdot (-0,5) = \mathbf{3,75}$.

Q-learning siempre toma el máximo; SARSA usa el valor de la acción realmente elegida, por eso su resultado varía con la exploración.

4. Q-learning: parámetros (interpretación)

En Q-learning, ¿qué efecto tiene usar valores extremos en cada parámetro? Analice: (a) $\alpha = 0$ y $\alpha = 1$; (b) $\gamma = 0$ y $\gamma = 1$; (c) $\varepsilon = 0$ y $\varepsilon = 1$.

Respuesta posible. (a) **α (tasa de aprendizaje)**. Con $\alpha = 0$ la actualización es nula: Q nunca cambia, no aprende. Con $\alpha = 1$ la nueva estimación reemplaza por completo a la vieja ($Q(S, A) = R + \gamma \max_a Q(S', a)$): aprende solo de la última experiencia, útil en ambientes determinísticos pero inestable si hay ruido.

(b) **γ (descuento)**. Con $\gamma = 0$ el agente es miope: solo maximiza la recompensa inmediata, ignora el futuro. Con $\gamma = 1$ pesa todas las recompensas futuras por igual; en tareas continuas el retorno puede diverger.

(c) **ε (exploración)**. Con $\varepsilon = 0$ es puramente greedy: nunca explora, puede quedar atrapado en una política subóptima. Con $\varepsilon = 1$ actúa siempre al azar: explora todo pero nunca aprovecha lo aprendido (aunque, al ser off-policy, Q-learning igual puede estimar la política óptima si visita suficientemente todos los pares).

5. Ambiente estocástico vs determinístico (interpretación)

En el juego “Cuatro en línea” (dos jugadores), ¿la función $p(s', r \mid s, a)$ que caracteriza el ambiente es estocástica o determinística? Justifique. ¿Qué significa que $\sum_{s', r} p(s', r \mid s, a) = 1$?

Respuesta posible. Desde la perspectiva del agente, el ambiente incluye al **oponente**. Si el oponente no juega siempre lo mismo (tiene una política estocástica o desconocida), entonces tras la acción del agente el estado resultante s' (que depende de la respuesta del rival) no es único: el ambiente es **estocástico**. Si el oponente fuera totalmente determinístico y conocido, p sería determinística. La regla del juego en sí es determinística, pero la dinámica p vista por el agente hereda la incertidumbre del rival.

$\sum_{s',r} p(s', r | s, a) = 1$ expresa que, fijados un estado s y una acción a , la distribución sobre todos los posibles pares (estado siguiente, recompensa) es una distribución de probabilidad válida: *algo* ocurre con certeza, y las probabilidades de todos los resultados posibles suman 1.

6. Temas avanzados (interpretación)

Los métodos de gradiente de políticas (p.ej. REINFORCE) se contraponen a los basados en función de valor. ¿Qué aprenden directamente y en qué casos conviene usarlos? Explique además, en una línea, qué hace Monte Carlo Tree Search (MCTS).

Respuesta posible. Los métodos de gradiente de políticas aprenden **directamente una política parametrizada** $\pi(a | s, \theta)$ (las probabilidades de cada acción), sin pasar por una función de valor q_* . Se ajustan los parámetros por ascenso de gradiente sobre una métrica de desempeño $J(\theta)$. En REINFORCE, la probabilidad de una acción **sube o baja proporcionalmente al retorno observado** G . Conviene cuando hay **demasiadas acciones**, acciones **continuas**, o cuando es más simple representar la política que el valor (operación de brazos robóticos, trading, LLMs).

MCTS: planificación en tiempo de decisión que construye incrementalmente un árbol desde el estado actual, simulando trayectorias (selección–expansión–simulación–backup) para estimar el valor de las acciones y elegir la mejor. Es el motor de búsqueda de AlphaGo.

Banco de preguntas extra (para practicar)

Bandidos de k brazos

- Explique el compromiso (*trade-off*) entre **exploración** y **explotación**. ¿Qué es una acción *greedy*?
- Diferencia entre $q_*(a)$ (valor real) y $Q_t(a)$ (estimación). ¿Por qué $Q_t(a) \rightarrow q_*(a)$ con el promedio muestral? (Ley de los Grandes Números).
- En el ejemplo de 10 brazos, ¿por qué $\varepsilon = 0,1$ termina eligiendo más la acción óptima que $\varepsilon = 0$ (greedy puro)?

Procesos de Decisión de Markov

- Distinga $v_\pi(s)$ de $q_\pi(s, a)$ y escriba la relación $q_\pi(s, a) = \mathbb{E}_\pi[R_{t+1} + \gamma v_\pi(S_{t+1}) | S_t=s, A_t=a]$.
- Exprese $p(s' | s, a)$ y $r(s, a)$ en función de $p(s', r | s, a)$ (marginalizando y tomando esperanza).
- Diferencia entre métodos **model-based** (p.ej. Value Iteration) y **model-free** (Monte Carlo, Q-learning). ¿Por qué casi siempre usamos model-free?
- ¿Qué es una política óptima π_* y las funciones óptimas v_*, q_* ?
- Modele el Tatetí como MDP: estados, acciones, recompensas, ¿es determinístico o estocástico?

Monte Carlo y Diferencias Temporales

- ¿Por qué el primer algoritmo MC para estimar π_* necesita una política ε -greedy y no una greedy pura? (Para visitar todos los pares (s, a)).

- Escriba la actualización incremental de la media de retornos: $Q \leftarrow Q + \frac{1}{k+1}(G^{(k+1)} - Q)$.
¿Con qué regla de bandidos se parece?
- Efecto de arrancar con ε alto (p.ej. 1) y bajarlo gradualmente hasta $\approx 0,01$ en MC. (Explorar mucho al principio, explotar al final).
- En el ejemplo “conduciendo a casa”, ¿por qué TD corrige la predicción en cada tramo y MC recién al llegar?

Deep Q-Learning y temas avanzados

- ¿Qué es el error cuadrático $\overline{QE}(\mathbf{w}) = \sum_{s,a} [q_*(s,a) - \hat{q}(s,a,\mathbf{w})]^2$ y cómo se lo reduce con SGD?
- ¿Por qué DQL se llama método *semi-gradiente* y por qué no garantiza convergencia (a diferencia del caso tabular)?
- Métodos **Actor-Critic**: ¿qué rol cumple el *actor* y qué rol el *crítico*? ¿En qué se diferencia de REINFORCE? (Bootstrapping / objetivo = error TD).
- Los cinco pasos de MCTS: selección, expansión, simulación, backup, repetir. Diferencia entre *política del árbol* y *política rollout*.
- **AlphaGo** vs **AlphaGo Zero**: ¿en qué se diferencian respecto del uso de datos humanos y del *self-play* (*tabula rasa*)?
- Preguntas para neurociencias: ¿tiene el cerebro un mecanismo parecido a ε -greedy? ¿Cómo se relaciona la recompensa de RL con la dopamina? ¿Hay algo análogo al *replay de experiencias* durante el sueño?