Trabajo Práctico 3: NLP

Inteligencia Artificial y Neurociencias

Fecha de entrega: **hasta Miércoles 11/11 a las 23:59hrs.**

Objetivo

Experimentar con distintos enfoques de NLP para clasificar la postura de comentarios en español y comparar sus resultados predictivos, costos computacionales y limitaciones.

La pregunta que deberá guiar los experimentos y las conclusiones es: **¿Cuándo conviene utilizar técnicas tradicionales de Machine Learning, modelos preentrenados o LLMs para resolver esta tarea de NLP?**

No se busca solamente obtener el mejor resultado, sino también entender qué mejoras aportan las distintas técnicas y si justifican sus costos.

Dataset

Se utilizará ALIA Spanish Stance Detection, que contiene 3.000 comentarios sobre propuestas ciudadanas distintas, cada uno con tres anotaciones humanas independientes: `favor`, `against` o `neutral`.

Consignas

1. Exploración y preparación de datos

- Explorar la distribución de clases, las características de los textos y el acuerdo entre anotadores.
- Analizar posibles formas de representar la variable objetivo (*majority voting*, *soft labels*, scores continuos u otras) y justificar la elección utilizada.
- Considerar técnicas de preprocesamiento (tokenización, lematización, eliminación de *stopwords*, normalización, etc.) y evaluar su utilidad cuando corresponda.

2. Modelos clásicos de NLP

- Construir un *baseline* combinando una representación textual (Bag-of-Words, TF-IDF, n-gramas, etc.) con un clasificador, como Regresión Logística, SVM o Random Forest entre otras de las técnicas vistas en TD VI.
- Experimentar con variantes de preprocesamiento, *features*, modelos o hiperparámetros para intentar mejorar el *baseline*.

3. Modelos preentrenados

- Seleccionar un encoder preentrenado (BETO, DistilBERT, RoBERTa u otro) y evaluarlo con y sin *fine-tuning* para la tarea.
- Probar algunas decisiones de entrenamiento (por ejemplo, *learning rate*, épocas o longitud máxima de secuencia) y analizar su efecto.

4. Large Language Models (LLMs)

- Seleccionar al menos un LLM ejecutado localmente o mediante API, y evaluar estrategias de *zero-shot* y *few-shot prompting*.
- Probar distintas instrucciones o selecciones de ejemplos para analizar cuánto puede mejorar el desempeño sin *fine-tuning*.
- Comparar la performance de distintos LLMs con diferentes estrategias o instrucciones también es un experimento válido.

5. Evaluación comparativa

Definir conjuntos de entrenamiento, validación y test (donde se evaluaran los experimentos). Las decisiones de entrenamiento y selección de configuraciones deberán tomarse sin utilizar este último conjunto.

La **métrica principal será Macro-F1 respecto del `majority_label`**, considerando las tres clases (`favor`, `against`, `neutral`). Se podrán utilizar otras representaciones del target durante el entrenamiento, siempre que las predicciones finales sean comparables mediante esta métrica.

Para cada enfoque, reportar:

- **Desempeño:** Macro-F1 y, cuando ayuden a interpretar los resultados, accuracy, F1 por clase o matriz de confusión.
- **Costos y recursos:** tiempo de entrenamiento (si corresponde) e inferencia. Pueden agregar algún detalle de recursos si utilizaron LLMs de forma local o hubo algún detalle de hardware (uso de N gbs de VRAM).

Presentar una comparación mediante gráficos o de forma resumida de los enfoques que permita relacionar las ventajas y desventajas de los diferentes enfoques probados.

Realizar una **conclusión** respondiendo la pregunta central del Trabajo Práctico con una breve reflexión personal grupal.

Recursos y entrega

El TP está diseñado para realizarse con recursos gratuitos (Kaggle Notebooks o Google Colab). Se recomienda utilizar modelos que puedan entrenarse o ejecutarse con los recursos disponibles en estas plataformas.

Algunos modelos sugeridos son:

- **Encoders y modelos preentrenados:** BETO, RoBERTuito, DistilBERT, XLM-RoBERTa, mT5 u otros similares.

- **Modelos generativos para prompting:** FLAN-T5, Qwen2.5 (1.5B–7B), Qwen3, Llama 3.2 o Gemma 3, entre otros.

Estas opciones son orientativas. Se podrán utilizar otros modelos siempre que sean adecuados para la tarea y los recursos disponibles.

Entregables: código o notebook reproducible (`.ipynb` o `.py s`) e informe (`.pdf`) con experimentos, resultados comparativos y conclusiones.

El informe tendrá una extensión máxima de **4 carillas**. El código deberá estar organizado de manera que sea sencillo reproducir los resultados presentados en el informe, incluyendo gráficos y tablas.

Modalidad de entrega: el TP se realizará en grupos de **2 a 4 integrantes**. Se deberá entregar un único archivo comprimido (`.zip` o `.tar.gz`) que contenga todos los entregables, con el siguiente formato de nombre:

`TP3_APELLIDO1_APELLIDO2_...`