Trabajo Práctico 3: NLP

Inteligencia Artificial y Neurociencias

Juan Ignacio Elosegui Juan Gonzalez Merlhe

1. Introducción

El objetivo de este trabajo fue comparar distintos métodos de NLP para clasificar la postura de comentarios en español frente a propuestas ciudadanas. Probamos tres enfoques: modelos clásicos de Machine Learning, modelos preentrenados y LLMs.

Buscamos comparar no solamente qué modelo obtiene mejores resultados, sino también sus costos computacionales y la complejidad de utilizarlos.

2. Dataset y preparación

Utilizamos el dataset ALIA Spanish Stance Detection, que contiene 3.000 comentarios en español. Cada comentario tiene tres anotaciones humanas independientes, con las siguientes categorías:

- **favor**: el comentario apoya la propuesta.
- **against**: el comentario se opone a la propuesta.
- **neutral**: no expresa una postura clara.

Elegimos como variable objetivo `majority_label`, es decir, la etiqueta elegida por la mayoría de los anotadores. Consideramos también la posibilidad de usar soft labels, pero preferimos majority voting para simplificar la comparación entre modelos.

Descartamos 150 comentarios en los que no había una etiqueta mayoritaria, quedando 2.850 observaciones.

Al explorar los datos observamos un desbalance entre las clases: el 62,5 % de los comentarios fueron favorables, el 22 % contrarios y el 15,5 % neutrales.

La longitud mediana de los comentarios fue de 266 caracteres y el promedio de 312,6 caracteres.

Respecto al acuerdo entre anotadores, encontramos que los tres coincidieron en el 51,3 % de los casos. En el 43,7 % hubo acuerdo de dos anotadores y en el 5 % restante los tres eligieron etiquetas diferentes. Esto muestra que algunos comentarios son difíciles de clasificar incluso para personas.

Para preparar los datos, combinamos la propuesta y el comentario en una única entrada de texto. Esto es importante porque la postura de un comentario depende de la propuesta a la que se refiere.

No aplicamos lematización ni eliminación de stopwords, ya que algunas palabras, especialmente las negaciones, pueden ser importantes para determinar la postura. Los modelos clásicos utilizaron TF-IDF y los modelos preentrenados sus propios tokenizadores.

Dividimos los datos en tres conjuntos:

- Entrenamiento: 70 % (1.995 ejemplos).
- Validación: 15 % (428 ejemplos).
- Test: 15 % (427 ejemplos).

Utilizamos una división aleatoria estratificada con semilla 42. Todos los modelos utilizaron las mismas particiones.

La métrica principal fue **Macro-F1**, que permite evaluar el desempeño considerando las tres clases por igual.

3. Modelos y experimentos

3.1. Modelos clásicos

Comenzamos con un baseline de TF-IDF y regresión logística. Luego probamos distintas representaciones del texto y clasificadores, incluyendo bigramas, n-gramas de caracteres y SVM.

También utilizamos un clasificador trivial que siempre predice la clase mayoritaria, para tener una referencia inicial.

Los resultados mejoraron considerablemente al combinar bigramas con balanceo de clases. El mejor modelo fue TF-IDF con unigramas y bigramas, junto con regresión logística balanceada.

3.2. Modelos preentrenados

Utilizamos BETO, un modelo BERT preentrenado en español.

Primero lo evaluamos sin fine-tuning, utilizando sus embeddings para entrenar una regresión logística balanceada.

Después realizamos fine-tuning, ajustando el modelo para nuestra tarea de clasificación.

Probamos dos learning rates ($2 \cdot 10^{-5}$ y $5 \cdot 10^{-5}$), entrenando durante tres épocas y utilizando una longitud máxima de 256 tokens.

El mejor resultado se obtuvo con el learning rate más bajo.

3.3. LLMs

Utilizamos Qwen2.5-1.5B-Instruct, ejecutado en Google Colab, sin realizar fine-tuning.

Comparamos tres estrategias:

- Zero-shot: instrucciones básicas sin ejemplos.
- Few-shot: tres ejemplos etiquetados, uno por clase.
- Zero-shot mejorado: instrucciones más específicas.

En el último caso agregamos instrucciones para distinguir postura de sentimiento y prestar atención a negaciones y comentarios ambiguos.

El prompt mejorado obtuvo los mejores resultados. Esto muestra que la forma de formular las instrucciones puede tener un impacto importante incluso sin modificar los pesos del modelo.

4. Resultados

La siguiente tabla muestra los resultados de los experimentos sobre el conjunto de validación.

Enfoque	**Modelo**	**Macro-F1**
Clásico	Dummy (clase mayoritaria)	0,2561
Clásico	TF-IDF + Regresión Logística	0,3153
Clásico	TF-IDF (1-2 gramas) + Regresión Logística balanceada	**0,4914**
Clásico	TF-IDF (1-2 gramas) + SVM balanceado	0,4818
Clásico	TF-IDF caracteres (3-5 gramas) + SVM balanceado	0,4543
Preentrenado	BETO congelado + Regresión Logística	0,4220
Preentrenado	BETO fine-tuning (lr=2e-5)	**0,5554**
Preentrenado	BETO fine-tuning (lr=5e-5)	0,5458
LLM	Qwen zero-shot	0,3964
LLM	Qwen few-shot	0,4083
LLM	Qwen zero-shot mejorado	**0,4472**

Cuadro 1: Resultados obtenidos en validación.

Una vez seleccionada la mejor configuración de cada enfoque, evaluamos los tres modelos sobre el conjunto de test.

Modelo	Macro-F1 Test	Inferencia (s)
BETO con fine-tuning	**0,5715**	1,22
TF-IDF + Bigramas	0,5350	0,073
Qwen con prompt mejorado	0,4090	38,20

Cuadro 2: Resultados finales sobre 427 comentarios de test.

BETO fue el modelo con mejor desempeño, aunque la diferencia respecto del modelo clásico fue relativamente pequeña.

Por otro lado, el modelo clásico fue mucho más rápido. Para clasificar los 427 comentarios de test necesitó solamente 0,073 segundos, frente a 1,22 segundos de BETO y 38,20 segundos de Qwen.

En cuanto al entrenamiento, los modelos clásicos necesitaron segundos, mientras que cada configuración de BETO con fine-tuning requirió aproximadamente un minuto en la ejecución final. Qwen no necesitó entrenamiento adicional.

Es importante aclarar que los tiempos se midieron en distintos entornos y dispositivos, por lo que la comparación es orientativa.

También observamos dificultades para clasificar los comentarios neutrales. Por ejemplo, en test el modelo clásico obtuvo un F1 de 0,35 para neutral, frente a 0,76 para favor. En Qwen, el F1 para neutral fue de 0,29.

5. Conclusiones

Los resultados muestran que no existe un único enfoque que sea el más conveniente en todas las situaciones.

BETO con fine-tuning obtuvo el mejor resultado predictivo. Por lo tanto, sería nuestra elección si buscamos maximizar el desempeño y contamos con recursos para entrenar el modelo.

Los modelos clásicos resultaron mucho más competitivos de lo que esperábamos. TF-IDF con bigramas y regresión logística obtuvo un resultado cercano al de BETO, con un costo computacional mucho menor. Creemos que sería la mejor alternativa para aplicaciones donde importan la velocidad, la simplicidad y los recursos disponibles.

Qwen tuvo el peor desempeño de los tres enfoques seleccionados. Si bien no requiere entrenamiento, su inferencia fue considerablemente más lenta. Sin embargo, observamos que mejorar las instrucciones produjo mejores resultados que agregar ejemplos few-shot.

Algo que nos llamó la atención fue que un modelo clásico tan sencillo pudiera superar al LLM generativo y acercarse bastante al encoder preentrenado. Esto demuestra que utilizar modelos más grandes o complejos no necesariamente implica mejores resultados.

Finalmente, reconocemos algunas limitaciones del trabajo. Utilizamos un dataset relativamente pequeño, una sola división de datos y un único LLM. Además, algunos comentarios presentan ambigüedades incluso entre anotadores humanos. Nuestra división aleatoria tampoco permite asegurar que los modelos generalicen a propuestas ciudadanas completamente nuevas.

Como trabajo futuro, sería interesante probar otros LLMs, repetir los experimentos con diferentes semillas y evaluar la generalización a propuestas no vistas durante el entrenamiento.